




دانشگاه صنعتی خواجه نصیرالدین طوسی
دانشکده مهندسی برق

پروژه کارشناسی

تشخیص بیماری پلاس در رتینوپاتی نارس
ارزیابی سهم بازنمایی عروقی فضایی و نشانگرهای
اسکالر عروقی در کنار بازنمایی یادگرفته‌شده‌ی تصویر

نام و نام خانوادگی	نیکی مهدیان
مقطع	کارشناسی
استاد راهنما	دکتر تقی راد
تاریخ	شهریور ۱۴۰۵

بِسْمِ اللَّهِ الرَّحْمَنِ الرَّحِيمِ


تأییدیه‌ی هیئت داوران

اعضای هیئت داوران، نسخه‌ی نهایی پروژه‌ی خانم نیک‌ی مہدی‌ان را با عنوان

تشخیص بیماری پلاس در رتینوپاتی نارس
ارزیابی سهم بازنمایی عروقی فضایی و نشانگرهای اسکالر عروقی در کنار بازنمایی
یادگرفته‌شده‌ی تصویر

از نظر شکل و محتوا بررسی نموده و پذیرش آن را برای تکمیل درجه‌ی کارشناسی تأیید می‌کنند.

عضو هیئت داوران	نام و نام خانوادگی	رتبه‌ی علمی	امضا
استاد راهنما	دکتر تقی راد		
استاد داور			



اظہارنامہ ی دانشجو

اینجانب نیکی مہدیان، دانشجوی مقطع کارشناسی، گواهی می‌نمایم که مطالب ارائه‌شده در این پروژه
با عنوان

تشخیص بیماری پلاس در رتینوپاتی نارس
ارزیابی سهم بازنمایی عروقی فضایی و نشانگرهای اسکالر عروقی در کنار بازنمایی
یادگرفته‌شده ی تصویر

با راهنمایی استاد محترم، دکتر تقی راد، توسط شخص اینجانب انجام شده است. صحت و اصالت
مطالب نوشته‌شده در این پروژه را تأیید می‌کنم و در تدوین متن پروژه، قالب مصوب دانشگاه صنعتی
خواجه نصیرالدین طوسی و اصول ارجاع‌دهی علمی را رعایت کرده‌ام.

تاریخ:

امضای دانشجو:

دانشگاه صنعتی خواجه نصیرالدین طوسی

حق طبع، نشر و مالکیت نتایج

۱- حق چاپ و تکثیر این پروژه متعلق به نویسنده و استاد راهنمای آن است. هرگونه تصویربرداری از کل یا بخشی از پروژه تنها با موافقت نویسنده، استاد راهنما یا کتابخانه‌ی دانشکده‌های مهندسی برق و کامپیوتر دانشگاه صنعتی خواجه نصیرالدین طوسی مجاز است.

۲- کلیه‌ی حقوق معنوی این اثر متعلق به دانشگاه صنعتی خواجه نصیرالدین طوسی است و بدون اجازه‌ی کتبی دانشگاه قابل واگذاری به شخص ثالث نیست.

۳- استفاده از اطلاعات و نتایج موجود در پروژه بدون ذکر مرجع مجاز نیست.

تقديم به

تشکر و قدردانی



چکیده

رتینوپاتی نارس^۱ شایع‌ترین علت نابینایی قابل‌پیشگیری در نوزادان نارس است و تصمیم درمانی در آن به تشخیص مرحله‌ی پلاس^۲ گره خورده است. این تشخیص بر ارزیابی چشمی متخصص از تصویر فوندوس تکیه دارد و در مرزهای خود وابسته به داور است. پژوهش حاضر یک خط لوله‌ی اندازه‌گیری و ارزیابی برای این مسئله می‌سازد و دو پرسش را می‌سنجد، اینکه آیا پنج نشانگر عروقی اسکالر به‌تنهایی پلاس را جدا می‌کنند و آیا افزودن آن‌ها به یک بازنمایی تصویری یادگرفته‌شده سود افزایشی می‌سازد.

ساخته‌ی این پروژه سه بخش دارد. بخش نخست پنج نشانگر عروقی اسکالر است که با تعریف مخرج پوشش بر پایه‌ی مساحت محتوا استخراج می‌شوند. بخش دوم دو بازنمایی منجمد است، بازنمایی تصویر RGB^۳ از EfficientNet-B5^۴ و بازنمایی نقشه‌ی عروق از EfficientNet-B4. بخش سوم هشت مدل اصلی است که از ترکیب همین اجزا ساخته می‌شوند، در کنار مدل‌های نوروئی ثانویه. جمعیت مطالعه ۸۸۶۲ تصویر از ۴۱۴ گروه در سه منبع تصویربرداری است که به‌صورت گروه‌محور تقسیم شده‌اند و هیچ گروهی در بیش از یک بخش قرار نمی‌گیرد.

افزودن بازنمایی فضایی عروق به بازنمایی تصویری، توان رتبه‌بندی و کیفیت احتمال را با بهبود پشتیبانی‌شده بهتر کرد. این افزایش در ارزیابی منبع کنارگذاشته، که هیچ داده‌ای از منبع هدف در آن به کار نمی‌رود، و با یک معماری تصویری متفاوت نیز تکرار شد. در برابر آن، پنج نشانگر اسکالر در هیچ‌یک از رژیم‌های آزمون‌شده سود افزایشی پشتیبانی‌شده نداشتند؛ به‌تنهایی از هر مدل تصویری این گزارش ضعیف‌تر ماندند و افزودنشان به ترکیب مشترک یادگیرنده تفاضل ناچیزی داد که پشتیبانی نشد.

عملکرد روی منبع دیده‌نشده به‌طور محسوس پایین‌تر از آزمون آمیخته است، ماسک مرجع با حاشیه‌نویسی متخصص برای این جمعیت وجود ندارد و منبع Plus به مقایسه‌ی محدود Normal در برابر Plus محدود می‌ماند، پس این نتیجه‌ها فقط توان رتبه‌بندی مدل را روی برچسب ثبت‌شده در این داده نشان می‌دهد و شواهدی برای آمادگی بالینی، جایگزینی ارزیابی متخصص یا اعتبارسنجی خارجی نیست.

واژه‌های کلیدی: رتینوپاتی نارس، بیماری پلاس، نشانگر عروقی، بازنمایی منجمد، ترکیب بازنمایی

^۱ رشد غیرطبیعی عروق شبکیه در نوزاد نارس؛ معادل انگلیسی: Retinopathy of Prematurity (ROP)

^۲ مرحله‌ی شدید تغییرات عروقی قطب خلفی با گشادشدگی و پیچ‌خوردگی رگ‌ها؛ معادل انگلیسی: Plus disease

^۳ تصویر رنگی سه‌کاناله‌ی فوندوس؛ معادل انگلیسی: Red-Green-Blue

^۴ معماری تصویری با مقیاس‌گذاری هم‌زمان عمق، عرض و وضوح؛ معادل انگلیسی: EfficientNet-B5



تصویری و عروقی، تقسیم گروه‌محور با اثر انگشت، بوت‌استرپ زوجی، ارزیابی منبع کنارگذاشته

جدول ۱-۰: اثبات یکپارچگی داده و نتایج؛ بازمحاسبه‌ی محلی روی تقسیم رسمی

مقدار	مورد
0d4c3b3a60761ca1...	اثر انگشت SHA-256 پرونده‌ی تقسیم رسمی
۸۸۷۰	تصویر در پرونده‌ی تقسیم کانونی
۸۸۶۲	تصویر در جمعیت تحلیل نهایی (موارد کامل)
۴۱۴	گروه
صفر	هم‌پوشانی گروه میان آموزش، اعتبارسنجی و آزمون
۰.۹۳۵ / ۰.۹۳۳ / ۰.۹۲۵	AUC آزمون کانونی: بازنمایی تصویری / تصویر + عروق / تصویر + عروق + نشانگرها



فهرست علائم و اختصارات

اختصار / اصطلاح	معنی
ROP	رتینوپاتی نارس؛ اختلال رشد عروق شبکیه در نوزاد نارس
ICROP3	طبقه‌بندی بین‌المللی رتینوپاتی نارس، ویرایش سوم
Plus	بیماری پلاس؛ مرحله‌ی شدید تغییرات عروقی قطب خلفی
Pre-Plus	وضعیت میانی میان ظاهر طبیعی و بیماری پلاس
AUC	سطح زیر منحنی مشخصه‌ی عملکرد گیرنده؛ معیار رتبه‌بندی مستقل از آستانه
ROC	منحنی مشخصه‌ی عملکرد گیرنده؛ نرخ مثبت درست در برابر نرخ مثبت نادرست
ECE	خطای کالیبراسیون انتظاری؛ فاصله‌ی میان اطمینان پیش‌بینی و دقت واقعی
SMD	تفاوت میانگین استانداردشده‌ی یک ویژگی میان دو جمعیت
DANN	شبکه‌ی عصبی تقابلی دامنه؛ آموزش با متمایزکننده‌ی دامنه و گرادیان معکوس
MMD	فاصله‌ی پیشینه‌ی میانگین‌ها؛ معیار فاصله‌ی دو توزیع در فضای ویژگی
FiLM	تعدیل خطی ویژگی با پارامترهای تولیدشده از ورودی شرطی
MILP	برنامه‌ریزی خطی عدد صحیح مختلط؛ صورت‌بندی بهینه‌سازی تخصیص گروه‌ها به تقسیم
SHA-256	تابع درهم‌سازی رمزنگاری برای اثر انگشت محتوای مصنوعات
XGBoost	پیاده‌سازی درخت‌های تقویت‌شده با گرادیان؛ طبقه‌بند مدل‌های بازنمایی



اختصار / اصطلاح	معنی
EfficientNet-B5	معماری تصویری با مقیاس‌گذاری هم‌زمان عمق، عرض و وضوح؛ رمزگذار تصویر RGB
EfficientNet-B4	معماری هم‌خانواده‌ی EfficientNet-B5 با ظرفیت کمتر؛ رمزگذار نقشه‌ی عروق
ResNet50	شبکه‌ی باقی‌مانده‌ی پنجاه‌لایه؛ یکی از دو ستون مدل توجه‌ی
timm	کتابخانه‌ی مدل‌های تصویری پایتورچ؛ منبع وزن‌های پیش‌آموزش‌دیده
PVBM	کتابخانه‌ی محاسبه‌ی نشانگرهای عروقی شبکه‌ی
HVDROPDB	مجموعه‌ی عمومی تصاویر شبکه‌ی نوزادان نارس با ماسک عروق متخصص



فهرست مطالب

آ	چکیده
پ	فهرست علائم و اختصارات
۱	۱ مقدمه
۱	۱-۱ مقدمه، سوالات پژوهش و خط زمانی
۱	۱-۱-۱ مسئله بالینی
۱	۱-۱-۲ فرضیه اولیه
۲	۱-۱-۳ مدل‌های مقایسه‌شده
۲	۱-۱-۴ روش پاسخگویی به پرسش‌ها
۲	۱-۱-۵ سوالات پژوهش و پاسخ نهایی
۳	۱-۱-۶ مشارکت‌های علمی
۳	۱-۱-۷ روایت زمانی کامل
۵	۲ مفاهیم پایه
۵	۲-۱ رتینوپاتی نارس و بیماری پلاس
۵	۲-۲ تصویر فوندوس و نقش آن
۶	۲-۳ بیومارکر عروقی
۶	۲-۴ شبکه کانولوشنی
۷	۲-۵ ترکیب زودهنگام و دیر هنگام
۸	۲-۶ تقسیم گروه‌محور و نشئت داده
۸	۲-۷ معیارهای ارزیابی
۱۰	۳ مرور مطالعات پیشین
۱۰	۳-۱ پیشینه و مرور ادبیات
۱۰	۳-۱-۱ رتینوپاتی نارس و غربالگری Plus



۱۰	سه خانواده روش	۲-۱-۳
۱۱	شبکه EfficientNet و کتابخانه timm	۳-۱-۳
۱۱	کتابخانه اندازه‌گیری عروقی	۴-۱-۳
۱۱	ارزیابی گروه‌آگاه در تصاویر پزشکی	۵-۱-۳
۱۲	غربالگری پلاس در عمل	۶-۱-۳
۱۲	سامانه‌های تحلیل تصویری پلاس	۷-۱-۳
۱۲	جایگاه این کار	۸-۱-۳

۱۳	تشریح موضوع و بیان مسئله	۴
۱۳	بیان مسئله	۱-۴
۱۳	چالش‌های کلیدی	۲-۴
۱۴	رویکرد این پروژه	۳-۴

۱۶	روش پیشنهادی و مدل‌سازی	۵
۱۶	داده، تقسیم استاندارد و ممیزی منشأ	۱-۵
۱۶	جمعیت کانونی و منابع داده	۱-۱-۵
۱۶	فضای برچسب	۲-۱-۵
۱۹	تقسیم استاندارد	۳-۱-۵
۱۹	جایگاه آزمون استاندارد در برابر تحلیل‌های ثانویه	۴-۱-۵
۲۰	تاریخچه‌ی توسعه، غیرقطعی	۵-۱-۵
۲۰	جداسازی عروق و پنج نشانگر نهایی	۲-۵
۲۰	جداساز عملیاتی	۱-۲-۵
۲۰	پنج نشانگر نهایی	۲-۲-۵
۲۱	محدودیت اعتبارسنجی جداسازی	۳-۲-۵
۲۲	پروتکل ارزیابی و آزمایش‌های اکتشافی	۳-۵
۲۲	سه رژیم ارزیابی	۱-۳-۵
۲۲	بوت‌استرپ زوجی طبقه‌محور	۲-۳-۵
۲۳	معیارهای گزارش	۳-۳-۵
۲۳	ارزیابی محدود منبع Plus	۴-۳-۵



۲۳	۵-۳-۵	قفل آزمون و پیکربندی تثبیت شده
۲۴	۶-۳-۵	مرور
۲۶	۷-۳-۵	مدل‌های ترکیب عصبی و FiLM
۲۷	۸-۳-۵	آموزش مدل‌های عصبی
۲۷	۹-۳-۵	مدل ناوردایی دامنه
۲۷	۱۰-۳-۵	شبه‌کد
۲۸	۴-۵	آزمون‌های خودکار و محافظ‌های یکپارچگی
۲۹	۶	آزمایش‌ها و تحلیل نتایج
۲۹	۱-۶	نتایج آزمون کانونی قفل شده
۲۹	۱-۱-۶	ترکیب جمعیت و تقسیم استاندارد
۳۶	۲-۱-۶	عملکرد مدل‌های اصلی
۳۶	۳-۱-۶	نمای چندمعیاره و رفتار هر کلاس
۴۴	۴-۱-۶	کالیبراسیون و جهت معیارهای آستانه‌ای
۴۴	۵-۱-۶	آمار زوجی مقایسه‌ای اصلی
۴۶	۶-۱-۶	ترکیب دیر هنگام: یک نتیجه منفی
۴۶	۲-۶	شواهد افزایشی پنج نشانگر اسکالر در همه‌ی رژیم‌های آزمون شده
۴۹	۳-۶	آزمایش‌های ثانویه و اکتشافی مدل‌های عصبی
۴۹	۱-۳-۶	ترکیب مشترک یادگیرنده (Task 9)
۵۰	۲-۳-۶	شرطی‌سازی نشانگری با تعدیل کران‌دار (Task 10)
۵۸	۳-۳-۶	استواری معماری نتیجه‌ی عروقی (Task 13)
۵۸	۴-۳-۶	جمع‌بندی بیش‌برازش
۵۹	۴-۶	استواری معماری سهم عروقی و تشخیص توجه
۶۲	۵-۶	جابه‌جایی دامنه‌ی بازنمایی‌ها و نشانگرها
۶۵	۶-۶	ارزیابی با منبع کنار گذاشته
۷۰	۷-۶	آزمون ناوردایی دامنه‌ی شرطی‌به‌کلاس
۷۴	۸-۶	جمع‌بندی تعمیم‌پذیری میان منابع
۷۵	۹-۶	تفسیر تصمیم آزمون ناوردایی



۷۶	۷ جمع‌بندی و نتیجه‌گیری
۷۶	۱-۷ بحث، محدودیت‌ها و نتیجه‌گیری
۷۶	۱-۱-۷ پاسخ به سؤال‌های پژوهش
۷۷	۲-۱-۷ محدودیت‌ها
۷۷	۳-۱-۷ ارزش علمی
۷۸	۴-۱-۷ پیامد برای کاربرد پژوهشی
۷۸	۵-۱-۷ کار آینده
۸۰	پیوست‌ها
۸۰	۲-۷ ضمیمه
۸۰	۱-۲-۷ آزمایش‌های منفی معماری
۸۰	۲-۲-۷ تشخیص‌های FiLM
۸۱	۳-۲-۷ منحنی‌های یادگیری Task 9
۸۱	۴-۲-۷ منحنی‌های یادگیری و توجه Task 13
۸۱	۵-۲-۷ اثر انگشت مصنوعات و یکپارچگی
۸۲	۶-۲-۷ داده‌ی خام شکل‌ها
۸۲	۷-۲-۷ قواعد نام‌گذاری و تعریف گروه
۸۲	۸-۲-۷ اثر انگشت تقسیم
۸۵	چکیده انگلیسی



فهرست تصاویر

- ۱-۵ توزیع کلاس در جمعیت نهایی به تفکیک منبع تصویربرداری (۸۸۶۲ تصویر، ۴۱۴ گروه). منبع Plus هیچ مورد Pre-Plus ندارد. ۱۷
- ۲-۵ سهم هر منبع در جمعیت نهایی. ۱۸
- ۳-۵ توزیع کلاس در تقسیم‌های آموزش، اعتبارسنجی و آزمون. ۱۸
- ۴-۵ خط لوله‌ی ساخت پنج نشانگر اسکالر از تصویر فوندوس و نقشه‌ی عروق. ۲۱
- ۵-۵ معماری و ابعاد ورودی مدل‌های اصلی. ۲۶
- ۱-۶ توان رتبه‌بندی مدل‌های اصلی روی آزمون کانونی (۱۳۳۱ تصویر). محور افقی از ۶۰.۰ آغاز شده و مقیاس مطلق برچسب‌گذاری شده است. ۳۱
- ۲-۶ سطح زیر منحنی چندکلاسه‌ی مدل‌های اصلی روی آزمون کانونی (۱۳۳۱ تصویر). بزرگ‌تر بهتر است. ۳۲
- ۳-۶ دقت متعادل مدل‌های اصلی روی آزمون کانونی (۱۳۳۱ تصویر). بزرگ‌تر بهتر است. ۳۲
- ۴-۶ افیک ماکروی مدل‌های اصلی روی آزمون کانونی (۱۳۳۱ تصویر). بزرگ‌تر بهتر است. ۳۳
- ۵-۶ امتیاز Brier مدل‌های اصلی روی آزمون کانونی (۱۳۳۱ تصویر). کوچک‌تر بهتر است. ۳۳
- ۶-۶ خطای کالیبراسیون انتظاری با پانزده سبد هم‌عرض برای مدل‌های اصلی روی آزمون کانونی (۱۳۳۱ تصویر). کوچک‌تر بهتر است. ۳۴
- ۷-۶ سطح زیر منحنی کلاس به صورت یک‌دربرابریه روی آزمون کانونی (۱۳۳۱ تصویر). ۳۴
- ۸-۶ سطح زیر منحنی کلاس به صورت یک‌دربرابریه روی آزمون کانونی (۱۳۳۱ تصویر). ۳۵
- ۹-۶ سطح زیر منحنی کلاس به صورت یک‌دربرابریه روی آزمون کانونی (۱۳۳۱ تصویر). ۳۵
- ۱۰-۶ سطح زیر منحنی هر کلاس به صورت یک‌دربرابریه روی آزمون کانونی (۱۳۳۱ تصویر). ۳۶
- ۱۱-۶ ماتریس درهم‌ریختگی مدل نشانگرهای اسکالر روی آزمون کانونی. سطرها کلاس واقعی و ستون‌ها کلاس پیش‌بینی شده‌اند؛ هر سطر به صد درصد جمع می‌شود و شمارش خام در پرانتز آمده است. ۳۷
- ۱۲-۶ ماتریس درهم‌ریختگی مدل بازنمایی تصویری روی آزمون کانونی. سطرها کلاس واقعی و ستون‌ها کلاس پیش‌بینی شده‌اند. ۳۸



- ۱۳-۶ ماتریس درهم‌ریختگی مدل تصویر به‌همراه عروق روی آزمون کانونی. سطرها کلاس واقعی و ستون‌ها کلاس پیش‌بینی شده‌اند. ۳۹
- ۱۴-۶ ماتریس درهم‌ریختگی مدل تصویر به‌همراه عروق و نشانگرها روی آزمون کانونی. سطرها کلاس واقعی و ستون‌ها کلاس پیش‌بینی شده‌اند. ۴۰
- ۱۵-۶ نمودار اطمینان‌پذیری سه مدل روی آزمون کانونی (۱۳۳۱ تصویر) با پانزده سبد هم‌عرض. خط‌چین مورب کالیبراسیون کامل است. ۴۱
- ۱۶-۶ تفاضل سطح زیر منحنی هر افزودنی نسبت به بازنمایی تصویری، با بازه‌ی اطمینان زوجی از بوت‌استرپ طبقه‌محور با ده هزار تکرار و بذر ثابت روی آزمون کانونی (۱۳۳۱ تصویر). خط‌چین صفر را نشان می‌دهد. ۴۳
- ۱۷-۶ شش آزمون مستقل سهم افزایشی پنج نشانگر اسکالر، با بازه‌ی اطمینان زوجی. سطر آخر ارزیابی محدود منبع Plus است. ۴۸
- ۱۸-۶ سهم افزایشی پنج نشانگر در ارزیابی با منبع کنارگذاشته، با بازه‌ی اطمینان زوجی. سطر Plus ارزیابی محدود است. ۴۹
- ۱۹-۶ خطای آموزش و اعتبارسنجی مدل‌های تسک نه به‌ازای هر دوره؛ رمزگذارها پس از دوره‌ی سوم آزاد شده‌اند. ۵۱
- ۲۰-۶ توان تمایز مدل‌های تسک نه روی اعتبارسنجی به‌ازای هر دوره. ۵۱
- ۲۱-۶ خطای آموزش و اعتبارسنجی مدل‌های تسک ده به‌ازای هر دوره. ۵۲
- ۲۲-۶ توان تمایز مدل‌های تسک ده روی اعتبارسنجی به‌ازای هر دوره. ۵۲
- ۲۳-۶ تعدیل یادگرفته‌شده‌ی FiLM روی آزمون؛ خط‌چین‌ها حالت همانی را نشان می‌دهند. ۲۴-۶ تغییر مطلق احتمال پیش‌بینی مدل تثبیت‌شده هنگام جایگزینی هر نشانگر با میانگین آموزشی خود. ۵۳
- ۲۵-۶ سطح زیر منحنی چندکلاسه‌ی مدل‌های تسک سیزده در برابر مدل‌های مرجع، روی آزمون کانونی (۱۳۳۱ تصویر). ۵۴
- ۲۶-۶ دقت متعادل مدل‌های تسک سیزده در برابر مدل‌های مرجع، روی آزمون کانونی (۱۳۳۱ تصویر). ۵۴
- ۲۷-۶ افیک ماکروی مدل‌های تسک سیزده در برابر مدل‌های مرجع، روی آزمون کانونی (۱۳۳۱ تصویر). ۵۵
- ۲۸-۶ امتیاز Brier مدل‌های تسک سیزده در برابر مدل‌های مرجع، روی آزمون کانونی (۱۳۳۱ تصویر). ۵۵



- ۲۹-۶ خطای کالیبراسیون انتظاری مدل‌های تسک سیزده در برابر مدل‌های مرجع، روی
آزمون کانونی (۱۳۳۱ تصویر). ۵۶
- ۳۰-۶ چهار مقایسه‌ی زوجی تسک سیزده، با بازه‌ی اطمینان از بوت‌استرپ طبقه‌محور با
ده هزار تکرار و بذر ثابت روی آزمون کانونی (۱۳۳۱ تصویر). ۵۶
- ۳۱-۶ خطای آموزش و اعتبارسنجی مدل تسک سیزده به‌ازای هر دوره؛ ستون‌های فقرات
پس از دوره‌ی سوم آزاد شده‌اند. ۵۷
- ۳۲-۶ توان تمایز مدل تسک سیزده روی اعتبارسنجی به‌ازای هر دوره. ۵۷
- ۳۳-۶ تفاضل سطح زیر منحنی از افزودن نمایش عروقی به دو بازنمایی تصویری متفاوت، با
بازه‌ی اطمینان زوجی روی آزمون کانونی (۱۳۳۱ تصویر). این شکل برتری معماری
دوستون فقرات را نشان نمی‌دهد. ۶۰
- ۳۴-۶ میانگین وزن توجه به شاخه‌ی ResNet بر حسب کلاس واقعی در آزمون. این وزن‌ها
فقط تشخیص توصیفی‌اند. ۶۰
- ۳۵-۶ میانگین وزن توجه به شاخه‌ی ResNet بر حسب منبع تصویربرداری. وابستگی
شدید به منبع، تفسیر بالینی این وزن‌ها را نامعتبر می‌کند. ۶۱
- ۳۶-۶ توزیع وزن توجه شاخه‌ی ResNet روی اعتبارسنجی؛ دامنه‌ی صدک پنج تا نود و
پنج با نشانگر میانه و میانگین. ۶۱
- ۳۷-۶ توزیع وزن توجه شاخه‌ی ResNet روی آزمون؛ دامنه‌ی صدک پنج تا نود و پنج با
نشانگر میانه و میانگین. ۶۲
- ۳۸-۶ جابه‌جایی دامنه‌ی نمایش تصویری میان منبع کنارگذاشته و منابع آموزشی. ۶۴
- ۳۹-۶ جابه‌جایی دامنه‌ی نمایش عروقی میان منبع کنارگذاشته و منابع آموزشی. ۶۴
- ۴۰-۶ فاصله‌ی مرکزوار استاندارد شده میان منبع کنارگذاشته و منابع آموزشی در دو نمایش. ۶۵
- ۴۱-۶ تفاوت میانگین استاندارد شده‌ی هر نشانگر میان منبع کنارگذاشته و منابع آموزشی. . ۶۶
- ۴۲-۶ سطح زیر منحنی سه‌کلاسه در ارزیابی با منبع کنارگذاشته. هیچ اطلاعاتی از منبع
هدف در برازش استفاده نشده است. ۶۸
- ۴۳-۶ ارزیابی محدود منبع Plus به‌صورت دودویی Normal در برابر Plus. محور از ۹۷۵.۰
آغاز شده و برچسب‌گذاری شده است؛ این عدد جانشین سطح زیر منحنی سه‌کلاسه
نیست. ۶۹
- ۴۴-۶ سهم افزایشی نمایش عروقی در هر فولد منبع کنارگذاشته، با بازه‌ی اطمینان زوجی.
سطر Plus ارزیابی محدود است. ۶۹



- ۴۵-۶ سطح زیر منحنی سه کلاسه‌ی دو مدل تسک دوازده روی منبع کنارگذاشته. منبع
هدف در هیچ مرحله‌ای استفاده نشده است. ۷۲
- ۴۶-۶ ارزیابی محدود منبع Plus در تسک دوازده به صورت دودویی Normal در برابر Plus.
محور از ۹۸۵.۰ آغاز شده و برچسب‌گذاری شده است. ۷۲
- ۴۷-۶ فاصله‌ی مرکزوار استانداردشده میان دو دامنه‌ی آموزشی، پیش و پس از هم‌ترازی. . . ۷۳
- ۴۸-۶ میانه‌ی قدر مطلق تفاوت میانگین استانداردشده میان دو دامنه‌ی آموزشی، پیش و
پس از هم‌ترازی. ۷۳
- ۴۹-۶ دقت پیش‌بینی هویت دامنه از روی نمایش، پیش و پس از هم‌ترازی. خط‌چین سطح
شانس را نشان می‌دهد. ۷۴
- ۱-۷ میانگین وزن توجه هر شاخه در هر دوره؛ خطوط چین آستانه‌های فروپاشی را نشان
می‌دهند. ۸۱



فهرست جداول

۱-۰	اثبات یکپارچگی داده و نتایج؛ بازمحاسبه‌ی محلی روی تقسیم رسمی	ب
۱-۵	ترکیب جمعیت نهایی موارد کامل به تفکیک منبع تصویربرداری	۱۷
۲-۵	تقسیم گروه‌محور استاندارد جمعیت موارد کامل	۱۹
۳-۵	ورودی و ابعاد مدل‌های اصلی	۲۵
۱-۶	گروه‌های آزمایشی فصل ششم، هدف و نتیجه‌ی اصلی هر گروه. سطرهای تقسیم کانونی روی آزمون قفل‌شده و دو سطر دیگر روی جمعیت همان منبع کنارگذاشته	
۳۰	محاسبه شده‌اند.	
۲-۶	ترکیب جمعیت نهایی موارد کامل به تفکیک منبع تصویربرداری	۳۱
۳-۶	عملکرد مدل‌های اصلی روی آزمون کانونی قفل‌شده ($N = 1331$)	۴۲
۴-۶	AUC هر کلاس به صورت یک‌دربرابری روی آزمون کانونی ($N = 1331$)	۴۳
۵-۶	آمار زوجی اصلی روی آزمون کانونی؛ بوت‌استرپ زوجی طبقه‌بندی‌شده با ۱۰۰۰۰	
۴۵	تکرار و بذر ۴۲ ($N = 1331$)	
۶-۶	شواهد افزایشی پنج نشانگر اسکالر در همه‌ی رژیم‌های آزمون‌شده	۴۷
۷-۶	آزمایش‌های ثانویه و اکتشافی معماری که از مدل‌های الحاقی تثبیت‌شده بهتر نشدند	۵۰
۸-۶	استواری سهم عروقی نسبت به معماری بازنمایی تصویری	۵۹
۹-۶	خلاصه‌ی جابه‌جایی دامنه‌ی نمایش‌های تثبیت‌شده؛ منبع کنارگذاشته در برابر منابع	
۶۳	آموزشی تجمیع‌شده	
۱۰-۶	عملکرد در ارزیابی با منبع کنارگذاشته؛ هیچ اطلاعاتی از منبع هدف در برازش یا	
۶۷	پیش‌پردازش استفاده نشده است	
۱۱-۶	نتایج آزمون ناوردایی دامنه‌ی شرطی به کلاس؛ K1 در برابر کنترل هم‌تای K0	۷۱
۱-۷	محدودیت‌های کلیدی و اثر آن‌ها بر دامنه‌ی ادعا	۷۷



فصل ۱

مقدمه

۱-۱ مقدمه، سوالات پژوهش و خط زمانی

هدف محاسباتی این پروژه رتبه‌بندی تصاویر فوندوس نوزادان نارس بر حسب سه وضعیت Normal^۵، Pre-Plus^۶ و Plus^۷ است. خروجی مدل می‌تواند ترتیب بازبینی تصاویر را تغییر دهد، اما جای معاینه و قضاوت چشم‌پزشک را نمی‌گیرد.

۱-۱-۱ مسئله بالینی

رتینوپاتی نارس یا ROP^۸ رشد عروق شبکیه را در نوزادان نارس مختل می‌کند و داده‌ی این پروژه سه وضعیت Normal، Pre-Plus و Plus را از هم جدا می‌کند. مرز این سه وضعیت با قضاوت متخصص تعیین می‌شود؛ همین وابستگی انگیزه‌ی ساخت یک زنجیره‌ی پردازشی^۹ قابل تکرار برای اولویت‌بندی موارد مشکوک است، به‌ویژه در مراکزی که دسترسی به متخصص محدود است.

۱-۱-۲ فرضیه اولیه

تعریف Plus بر شکل رگ استوار است، پس کمیت‌هایی که مستقیماً از ماسک عروق اندازه‌گیری می‌شوند باید بخشی از همان نشانه را در خود داشته باشند. فرض اولیه‌ی پروژه از این جا آمد؛ اندازه‌گیری صریح عروقی می‌تواند به‌تنهایی رتبه‌بندی معناداری بدهد یا پس از افزودن به یک بازنمایی تصویری آموخته‌شده آن را بهتر کند. دو سطح این اندازه‌گیری، پنج نشانگر اسکالر و بازنمایی فضایی نقشه‌ی عروق، جداگانه آزموده شدند.

^۵شبکیه‌ی بدون نشانه‌ی پلاس؛ معادل انگلیسی: Normal

^۶وضعیت میانی میان ظاهر طبیعی و پلاس؛ معادل انگلیسی: Pre-Plus

^۷گشادشدگی و پیچ‌خوردگی پیش‌رونده‌ی عروق قطب خلفی؛ معادل انگلیسی: Plus

^۸بیماری رشد غیرطبیعی عروق شبکیه در نوزاد نارس؛ معادل انگلیسی: Retinopathy of Prematurity

^۹زنجیره‌ی گام‌های پردازش از داده‌ی خام تا ارزیابی؛ معادل انگلیسی: pipeline



۳-۱-۱ مدل‌های مقایسه‌شده

مدل‌های نهایی روی یک تقسیم و یک پروتکل آماری واحد سنجیده شده‌اند؛ پنج نشانگر اسکالر با XGBoost^{۱۰}، تصویر رنگی با EfficientNet-B5^{۱۱} و طبقه‌بند خطی، همان بازنمایی تصویری با XGBoost، تصویر به‌همراه پنج نشانگر، نقشه‌ی عروق با یک شبکه‌ی تصویری و طبقه‌بند خطی، و دو ترکیب الحاقی. ترکیب دیرهنگام هم ضریب اختلاطش را روی مرز اشباع کرد و به بازنمایی تصویری فروریخت.

چند مدل عصبی ثانویه هم اجرا شد؛ دو رمزگذار تثبیت‌شده با تعامل یادگیرنده، کنترل هم‌تای همان مدل، نسخه‌ی شرطی‌شده با تعدیل خطی کران‌دار، یک جفت کنترل و متمایزکننده‌ی دامنه، و یک ستون فقرات تصویری دوم با توجه نرم دو شاخه. این‌ها اکتشافی‌اند و نتیجه‌ی اصلی نیستند.

۴-۱-۱ روش پاسخگویی به پرسش‌ها

پاسخ‌ها روی یک تقسیم استاندارد قفل‌شده و گروه‌محور گرفته شده‌اند؛ اندازه و ترکیب بخش‌های آن در **جدول ۲-۶** آمده و هیچ گروهی در بیش از یک بخش نیست. انتخاب مدل، آستانه و پیکربندی فقط با داده‌ی اعتبارسنجی انجام شد و آزمون قفل‌شده برای نتیجه‌ی اصلی به کار رفت. مقایسه‌ها با بوت‌استرپ زوجی طبقه‌بندی‌شده و بذر ثابت بسته شدند تا برای هر مقایسه تفاضل و بازه‌ی اطمینان گزارش شود. انتقال به منبع تازه با سه فولد منبع کنارگذاشته سنجیده شد که در آن‌ها منبع هدف نه در برازش، نه در پیش‌پردازش و نه در انتخاب مدل وارد نشد.

۵-۱-۱ سوالات پژوهش و پاسخ نهایی

پرسش نخست این بود که اندازه‌گیری صریح عروقی تا چه حد Plus را از دو وضعیت دیگر جدا می‌کند. پنج نشانگر اسکالر به‌تنهایی رتبه‌بندی ضعیفی بالاتر از تصادف دادند و نقشه‌ی عروق وضع بهتری داشت، ولی هر دو پایین‌تر از مسیر تصویری ماندند (**جدول ۳-۶**). جداکردن صریح Plus ممکن است، اما در این داده از آموختن شکل رگ از خود تصویر ضعیف‌تر است.

پرسش دوم درباره‌ی سود افزودن اندازه‌گیری به بازنمایی آموخته‌شده بود. افزودن پنج نشانگر اسکالر تفاضل ناچیزی داد که بازه‌ی اطمینان آن صفر را در بر می‌گرفت و افزودن همان نشانگرها پس از بازنمایی عروقی هم افزایش پشتیبانی‌شده‌ای نساخت (**جدول ۵-۶**). در برابر آن، افزودن بازنمایی فضایی

^{۱۰}پایاده‌سازی درخت‌های تقویت‌شده با گرادیان؛ معادل انگلیسی: XGBoost

^{۱۱}معماری تصویری با مقیاس‌گذاری هم‌زمان عمق، عرض و وضوح؛ معادل انگلیسی: EfficientNet-B5



عروق هم رتبه‌بندی و هم کیفیت احتمال را بهتر کرد؛ این نتیجه در دو فولد منبع کنارگذاشته‌ی قابل مقایسه و با یک ستون فقرات تصویری متفاوت هم به‌دست آمد (جدول ۶-۱۰ و جدول ۶-۸). پرسش سوم انتقال به منبع دیده‌نشده بود. عملکرد روی منبع سه‌کلاسه‌ی کنارگذاشته به‌طور محسوسی پایین‌تر از آزمون آمیخته است. منبع Plus هیچ مورد Pre-Plus ندارد، پس فقط معیار دودویی محدود Normal در برابر Plus با همان برچسب صریح گزارش می‌شود و در کنار معیار سه‌کلاسه‌ی آزمون آمیخته خوانده نمی‌شود (جدول ۶-۱۰).

۶-۱-۱ مشارکت‌های علمی

خط اندازه‌گیری عروقی این پروژه از نو ساخته و تثبیت شد و پنج نشانگر نهایی با مخرج پوشش بر پایه‌ی مساحت محتوا تعریف شدند. جمعیت کانونی و تقسیم گروه‌محور با اثر انگشت SHA-256^{۱۲} قفل شد. پروتکل ارزیابی نیز بخشی از دستاورد است؛ انتخاب مدل و آستانه فقط با اعتبارسنجی انجام شد، آزمون قفل‌شده برای نتیجه‌ی اصلی مصرف گردید و برای هر مقایسه تفاضل و بازه‌ی اطمینان گزارش می‌شود. انتقال با سه فولد منبع کنارگذاشته و بدون هیچ استفاده‌ای از منبع هدف سنجیده شد و یک ستون فقرات تصویری دوم نشان داد نتیجه به یک معماری خاص بسته نیست. اثر انگشت مصنوعات هم ثبت شد.

بازنمایی عروقی فضایی اطلاعات مکمل و تکرارپذیری به رتبه‌بندی اضافه می‌کند، در حالی که پنج نشانگر اسکالر افزایش پشتیبانی‌شده‌ای ساختند. این‌ها نسبت به برچسب ثبت‌شده در همین داده سنجیده شده‌اند و برای ادعای کاربرد بالینی کافی نیستند.

۷-۱-۱ روایت زمانی کامل

ترتیب اجرای پروژه بخشی از روش‌شناسی ارزیابی است، چون اعتبار هر عدد به نسخه‌ی تقسیم و به زمانی بستگی دارد که مجموعه‌ی آزمون دیده شده است. آن مرز در این پروژه یک بار و پیش از هر مقایسه‌ای مشخص شد.

کار با سه منبع تصویربرداری آغاز شد. پس از پاک‌سازی، مواردی که نشانگر فراکتالی نامعتبر داشتند کنار گذاشته شدند و جمعیت کانونی تثبیت شد. خط اندازه‌گیری عروقی پیش از قفل تقسیم بازسازی شد و پنج نشانگر نهایی با مخرج پوشش بر پایه‌ی مساحت محتوا تعریف گردیدند. سپس تقسیم گروه‌محور ساخته و با اثر انگشت قفل شد و از آن لحظه هر مدل روی همان تقسیم اجرا شد، بدون هیچ گروه مشترک

^{۱۲}تابع درهم‌ساز رمزنگاری‌شده برای ثبت یکتای یک فایل؛ معادل انگلیسی: SHA-256



میان بخش‌ها؛ شمار هر بخش در **جدول ۶-۲** آمده است. مقایسه‌ی اصلی یک بار روی آزمون قفل‌شده انجام شد و انتخاب مدل، آستانه و پیکربندی تنها با اعتبارسنجی صورت گرفت. آزمایش‌های بعدی به ترکیب یادگیرنده، انتقال به منبع دیده‌نشده، ناوردایی دامنه و تکرار پرسش عروقی با یک ستون فقرات تصویری متفاوت پرداختند. در فولدهای منبع کنارگذاشته، منبع هدف نه در برازش، نه در پیش‌پردازش و نه در انتخاب مدل وارد نشد؛ در آزمایش ناوردایی دامنه هم قابلیت پیش‌بینی هویت دامنه از بازنمایی اندازه‌گیری شد. تحلیل‌های بعدی همه بازتحلیل اکتشافی ثانویه روی همان تقسیم قفل‌شده‌اند و مجموعه‌ی نگه‌داشته‌شده‌ی تازه‌ای برای تأیید نمی‌سازند.



فصل ۲

مفاهیم پایه

۱-۲ رتینوپاتی نارس و بیماری پلاس

شبکیه در دوران جنینی شبکه‌ی عروقی خود را کامل می‌کند و تولد زودرس می‌تواند این روند را مختل کند و به رتینوپاتی نارس یا ROP^{۱۳} بینجامد. داده‌ی این پروژه سه وضعیت Normal^{۱۴}، Pre-Plus^{۱۵} و Plus^{۱۶} را از هم جدا می‌کند. طبقه‌بندی بین‌المللی ویرایش سوم ICROP3^{۱۷} بر پیوستگی این تغییرات و نقش قضاوت متخصص در مرزگذاری تأکید دارد، پس مرز میان Pre-Plus و Plus پیوسته است و نه دو حالت جدا.

تعریف Plus بر شکل رگ استوار است، پس کمیتی که مستقیماً از ماسک عروق اندازه‌گیری می‌شود باید بخشی از آن را در خود داشته باشد. دو راه برای استفاده از این مشاهده وجود دارد؛ اندازه‌گیری صریح از ماسک عروق، یا سپردن همان کار به یک شبکه‌ی تصویری که شکل رگ را از پیکسل می‌آموزد.

۲-۲ تصویر فوندوس و نقش آن

تصویر فوندوس^{۱۸} مسیر عروق، دیسک بینایی و بافت اطراف را در یک قاب ثبت می‌کند. یک شبکه‌ی تصویری می‌تواند شکل رگ را همراه با رنگ و بافت بیاموزد، بدون آنکه کسی مختصات رگ را به آن بدهد. همین آزادی منبع خطا هم هست، چون تصویر افزون بر بیماری، شرایط ثبت مانند دوربین، نور و کادربندی را نیز حمل می‌کند و مدل می‌تواند بخشی از تصمیم خود را به آن‌ها ببندد.

این خطر در داده‌ی چندمرکزی جدی‌تر می‌شود، چون تصاویر این پروژه از سه منبع مستقل آمده‌اند و شرایط ثبت یکسان نیست؛ اگر یک نشانه‌ی ثبت با توزیع برچسب‌ها همبسته باشد، مدل می‌تواند بدون

^{۱۳}بیماری رشد غیرطبیعی عروق شبکیه در نوزاد نارس؛ معادل انگلیسی: Retinopathy of Prematurity

^{۱۴}شبکیه‌ی بدون نشانه‌ی پلاس؛ معادل انگلیسی: Normal

^{۱۵}وضعیت میانی میان ظاهر طبیعی و پلاس؛ معادل انگلیسی: Pre-Plus

^{۱۶}گشادشدگی و پیچ‌خوردگی پیش‌رونده‌ی عروق قطب خلفی؛ معادل انگلیسی: Plus

^{۱۷}مرجع بین‌المللی طبقه‌بندی رتینوپاتی نارس؛ معادل انگلیسی: ICROP3

^{۱۸}عکس رنگی از سطح داخلی پشت چشم شامل عروق و دیسک بینایی؛ معادل انگلیسی: fundus image



آموختن بیماری روی داده‌ی آمیخته عدد خوبی بگیرد. به همین دلیل جابه‌جایی بازنمایی‌ها میان منابع بدون استفاده از برچسب هدف اندازه‌گیری شد و سه فولد منبع کنار گذاشته ساخته شد که در آن‌ها منبع هدف نه در برازش، نه در پیش‌پردازش و نه در انتخاب مدل دیده نمی‌شود.

۳-۲ بیومارکر عروقی

برای ساختن بیومارکر^{۱۹}، مدل جداسازی عروق^{۲۰} ابتدا احتمال عروقی بودن هر پیکسل را محاسبه می‌کند، آستانه‌گذاری این نقشه یک ماسک دودویی می‌سازد و کمیت‌های نهایی از همان ماسک درمی‌آیند. حذف یک رگ باریک یا شمردن یک انعکاس نور به‌عنوان رگ، مقدار بیومارکر را جابه‌جا می‌کند. این پروژه با پنج نشانگر اسکالر بسته شد؛ چگالی عروق در میدان دید `vessel_density_fov`، چگالی خط مرکزی `skel_density_fov` و سه بُعد فراکتالی `fractal_d0`، `fractal_d1` و `fractal_d2`. مخرج کمیت‌های چگالی بر پایه‌ی مساحت محتوا تعریف شد، نه مساحت کل کادر؛ شمردن ناحیه‌ی سیاه یا بیرون از میدان دید در مخرج، چگالی را به کادربندی گره می‌زند. کیفیت این اندازه‌گیری یک محدودیت باز دارد؛ ماسک مرجع متخصص در دسترس نبود، پس صحت جداسازی در برابر مرز انسانی سنجیده نشد و آنچه تأیید شده فقط کامل بودن فنی خروجی‌هاست. خود نشانگرها هم وابسته به منبع‌اند و یک نشانگر ثابت در سه مرکز عدد یکسانی نمی‌دهد.

۴-۲ شبکه کانولوشنی

مسیر تصویری این پروژه از یک تصویر رنگی RGB^{۲۱} شروع می‌شود و به EfficientNet-B5^{۲۲} می‌رسد. خروجی این شبکه پیش از طبقه‌بند نهایی یک بردار بازنمایی^{۲۳} است. برخلاف نشانگرها، ابعاد این بردار معنای هندسی نام‌دار ندارند و اطلاعات شکل رگ، رنگ و بافت در همان ابعاد پخش شده است. همین بردار در دو نقطه به کار می‌رود؛ در یک مدل یک طبقه‌بند خطی روی آن می‌نشیند و در مدل دیگر همان بردار به‌صورت بازنمایی ثابت به XGBoost^{۲۴} داده می‌شود. این تفکیک عملی است؛ با حجم آموزش این مجموعه، تنظیم دقیق کل شبکه بخشی از ظرفیت را صرف برازش نویز می‌کند، در حالی که بازنمایی ثابت تکرارپذیرتر است و مقایسه با نشانگرهای اسکالر را ممکن می‌کند. مسیر عروقی معماری

^{۱۹} ویژگی اندازه‌گیری شده و قابل نام‌گذاری از شکل یا چگالی رگ؛ معادل انگلیسی: biomarker

^{۲۰} جدا کردن پیکسل‌های رگ از پس‌زمینه‌ی تصویر؛ معادل انگلیسی: vessel segmentation

^{۲۱} سه کانال رنگ سرخ، سبز و آبی؛ معادل انگلیسی: Red-Green-Blue

^{۲۲} معماری تصویری با مقیاس‌گذاری هم‌زمان عمق، عرض و وضوح؛ معادل انگلیسی: EfficientNet-B5

^{۲۳} بردار عددی فشرده‌ای که شبکه از تصویر می‌سازد؛ معادل انگلیسی: embedding

^{۲۴} پیاده‌سازی درخت‌های تقویت‌شده با گرادیان؛ معادل انگلیسی: XGBoost



مشابهی دارد؛ نقشه‌ی عروق به EfficientNet-B4^{۲۵} داده می‌شود و یک بردار بازنمایی عروقی می‌سازد. ورودی این مسیر خودش یک اندازه‌گیری است، نه تصویر خام، پس خطای جداسازی به آن ارث می‌رسد.

۵-۲ ترکیب زودهنگام و دیرهنگام

ساده‌ترین راه استفاده‌ی هم‌زمان از دو نوع اطلاعات، چسباندن آن‌ها پیش از طبقه‌بند است؛ این الگو ترکیب زودهنگام^{۲۶} نام دارد. الحاق ساده اما یک اشکال ساختاری دارد؛ پنج نشانگر در برابر صدها ستون تصویری سهم کوچکی از ستون‌ها را می‌سازند و یک ستون نشانگری باید در گره‌های درخت از میان ستون‌های تصویری جلو بزند، در حالی که اطلاعات هندسی آن تا حدی در بلوک تصویری هم حاضر است، چون ماسک عروق از همان تصویر ساخته شده است.

ترکیب دیرهنگام^{۲۷} جای دیگری از همین طیف است؛ امتیاز دو مدل مستقل با یک ضریب وزنی مخلوط می‌شود. در این پروژه ضریب اختلاط روی مرز اشباع شد و نسخه‌ی ترکیب دیرهنگام عملاً به بازنمایی تصویری فرو ریخت.

ترکیب یادگیرنده پاسخ دیگری به همان اشکال ساختاری بود؛ در مدل‌های ترکیب مشترک، دو رمزگذار تثبیت‌شده هر کدام یک بردار بازنمایی می‌دهند و یک تعامل یادگرفته‌شده آن‌ها را به یک MLP^{۲۸} می‌رساند. این طرح در عمل بدتر شد و افزودن نشانگر به همین شبکه هم کاهش پشتیبانی‌شده داد (جدول جدول ۶-۷). خطای آموزش این سرها پایین رفت و خطای اعتبارسنجی بالا، و کمینه‌ی خطای اعتبارسنجی در دوره‌ی نخست بود؛ با حجم آموزش این مجموعه، این سرها بیش‌برازش می‌کنند. قید شرطی کران‌دار آخرین پاسخ آزموده‌شده بود؛ در مدل شرطی‌شده، نشانگرها یک ضریب و یک بایاس کوچک می‌سازند که بازنمایی عروقی را با FiLM^{۲۹} بازتنظیم می‌کند. پارامترسازی باقی‌مانده و کران‌دار انتخاب شد تا مقدار اولیه نزدیک همانی بماند و تشخیص‌ها نشان می‌دهند این شرطی‌ساز عملاً همان‌طور ماند؛ جایگزینی هر نشانگر با میانگین آموزشی‌اش تصمیم هیچ نمونه‌ای را عوض نکرد، پس بهبود کالیبراسیون آن نسبت به کنترل هم‌تایش را نمی‌توان به نشانگرها نسبت داد. این نکته به‌عنوان محدودیت طرح تطبیقی در فصل نتایج ثبت شده است.

^{۲۵} معماری تصویری با مقیاس‌گذاری هم‌زمان عمق، عرض و وضوح؛ معادل انگلیسی: EfficientNet-B4

^{۲۶} ترکیب ویژگی‌ها پیش از طبقه‌بند نهایی؛ معادل انگلیسی: early fusion

^{۲۷} ترکیب احتمال یا امتیاز چند مدل مستقل پس از پیش‌بینی؛ معادل انگلیسی: late fusion

^{۲۸} شبکه‌ی عصبی چندلایه‌ی متصل؛ معادل انگلیسی: Multi-Layer Perceptron

^{۲۹} تعدیل خطی ویژگی با پارامترهای تولیدشده از ورودی شرطی؛ معادل انگلیسی: Feature-wise Linear Modulation



۶-۲ تقسیم گروه محور و نشت داده

یک نوزاد ممکن است در یک معاینه چند تصویر نزدیک به هم داشته باشد؛ اگر یکی در آموزش و دیگری در آزمون بیفتد، مدل ویژگی‌های ثابت همان چشم یا دستگاه را به خاطر می‌سپارد و برآورد عملکرد بالا می‌رود. تقسیم گروه محور همه‌ی تصاویر مرتبط را در یک بخش نگه می‌دارد.

جمعیت کانونی این پروژه ۸۸۶۲ مورد کامل در ۴۱۴ گروه است که با تقسیم گروه محور به سه بخش آموزش، اعتبارسنجی و آزمون رسید و هیچ گروهی در بیش از یک بخش نیست (جدول جدول ۶-۲). تقسیم یک بار ساخته و با اثر انگشت قفل شد و همه‌ی مدل‌های این گزارش روی همان اجرا شده‌اند. تعریف گروه در سه منبع یکسان نیست؛ در منبع Plus^{۳۰} و در FARFUM-RoP^{۳۱} گروه در سطح بیمار و در فارابی در سطح معاینه تعریف شد، چون شناسه‌ی بیمار در آن منبع وجود نداشت. پس در فارابی، نبود هم‌پوشانی معاینه نبود هم‌پوشانی بیمار را اثبات نمی‌کند.

۷-۲ معیارهای ارزیابی

احتمال پیش‌بینی شده با یک آستانه به تصمیم تبدیل می‌شود و تغییر آستانه، حساسیت و اختصاصیت را هم‌زمان جابه‌جا می‌کند. منحنی مشخصه‌ی عملکرد گیرنده^{۳۲} همین بده‌بستان را در همه‌ی آستانه‌ها نشان می‌دهد و سطح زیر آن^{۳۳} یک خلاصه‌ی رتبه‌بندی است، نه دقت تصمیم در یک آستانه. آستانه‌ی تصمیم در این پروژه با شاخص یودن^{۳۴} فقط روی اعتبارسنجی انتخاب شد و روی آزمون دوباره تنظیم نشد.

سه معیار دیگر مکمل همین تصویرند. دقت متعادل میانگین بازخوانی سه کلاس است و به نابرابری اندازه‌ی کلاس‌ها حساس نیست، اما مانند F1 ماکرو^{۳۵} به آستانه وابسته است. امتیاز Brier^{۳۶} و خطای کالیبراسیون انتظاری ECE^{۳۷} کیفیت خود احتمال را می‌سنجند و کوچک‌تر بودنشان بهتر است. این پنج معیار در هیچ امتیاز ترکیبی ادغام نشده‌اند، چون جهت‌های متفاوت آن‌ها را نمی‌توان ساده جمع کرد. مجموعه‌ی آزمون این پروژه یک تقسیم استاندارد قفل شده است که نتیجه‌ی اصلی روی آن محاسبه

^{۳۰} بزرگ‌ترین منبع تصویربرداری این مجموعه؛ معادل انگلیسی: Plus

^{۳۱} مجموعه‌ی عمومی تصاویر رتینوپاتی نارس؛ معادل انگلیسی: FARFUM-RoP

^{۳۲} منحنی بده‌بستان حساسیت و نرخ مثبت کاذب در آستانه‌های مختلف؛ معادل انگلیسی: ROC

^{۳۳} سطح زیر منحنی ROC؛ خلاصه‌ی توان رتبه‌بندی مدل؛ معادل انگلیسی: AUC

^{۳۴} آستانه‌ای که مجموع حساسیت و اختصاصیت را بیشینه می‌کند؛ معادل انگلیسی: Youden index

^{۳۵} میانگین هارمونیک دقت و بازخوانی؛ معادل انگلیسی: F1 score

^{۳۶} میانگین مربع خطای احتمال پیش‌بینی؛ معادل انگلیسی: Brier score

^{۳۷} خطای کالیبراسیون انتظاری؛ معادل انگلیسی: Expected Calibration Error



شده؛ بنابراین تحلیل‌های بعدی روی همان تقسیم، بازتحلیل اکتشافی ثانویه‌اند و نه یک مجموعه‌ی نگه‌داشته‌شده‌ی تازه برای تأیید. همه‌ی مقایسه‌ها با یک پروتکل واحد و بوت‌استرپ زوجی طبقه‌بندی‌شده سنجیده شده‌اند.



فصل ۳

مرور مطالعات پیشین

۱-۳ پیشینه و مرور ادبیات

پیشینه‌ی این پژوهش سه انتخاب روش‌شناختی را پوشش می‌دهد؛ استخراج کمیت‌های هندسی از عروق، استفاده از شبکه‌ی تصویری به‌عنوان خط پایه، و جداسازی بیماران یا معاینات هنگام تقسیم داده. تفاوت جامعه، دستگاه تصویربرداری و تعریف خروجی اجازه نمی‌دهد داده‌های مطالعات مختلف بدون بررسی این جزئیات با نتایج حاضر مقایسه شوند.

۱-۱-۳ رتینوپاتی نارس و غربالگری Plus

رتینوپاتی نارس یا ROP^{۳۸} در نوزادان با وزن تولد پایین شایع است و یکی از علل مهم نابینایی قابل پیشگیری در کودکان به‌شمار می‌رود. طبقه‌بندی بین‌المللی ویرایش سوم Plus^{۳۹} و Pre-Plus^{۴۰} را بخشی از یک طیف تغییرات عروقی می‌داند و بر ارزیابی عروق قطب خلفی تأکید می‌کند [۱]. تعریف Plus بر گشادشدگی و پیچ‌خوردگی همین عروق استوار است و مرزهای آن با قضاوت متخصص تعیین می‌شود؛ توافق متخصصان بر این تشخیص کامل نیست. غربالگری به‌موقع این نوزادان بخشی از مراقبت استاندارد است [۲] و خودکارسازی از روی فوندوس می‌تواند دسترسی را بهبود دهد، اما ارزیابی منصفانه بدون جداسازی گروهی داده شرط پذیرش علمی است و عدد بالا روی تقسیم نادرست ارزش بالینی ندارد.

۲-۱-۳ سه خانواده روش

شبکه‌ی کانولوشنی سرتاسری^{۴۱} الگو را مستقیماً از رنگ و بافت تصویر می‌آموزد. مدل جدولی بر دانش قبلی درباره‌ی شکل رگ تکیه دارد و ویژگی‌های قابل‌نام‌گذاری تولید می‌کند، اما خطای ماسک عروق را

^{۳۸}بیماری رشد غیرطبیعی عروق شبکه در نوزاد نارس؛ معادل انگلیسی: Retinopathy of Prematurity

^{۳۹}گشادشدگی و پیچ‌خوردگی پیش‌رونده‌ی عروق قطب خلفی؛ معادل انگلیسی: Plus

^{۴۰}وضعیت میانی میان ظاهر طبیعی و پلاس؛ معادل انگلیسی: Pre-Plus

^{۴۱}شبکه‌ای که از پیکسل خام تا برچسب نهایی یکپارچه آموزش می‌بیند؛ معادل انگلیسی: end-to-end CNN



نیز به طبقه‌بند منتقل می‌کند. ترکیب این دو مسیر فقط زمانی سودمند است که اطلاعات افزوده مکمل بازنمایی تصویر باشد؛ به همین دلیل نتیجه‌ی شاخه‌ی ترکیبی بدون مقایسه با بازنمایی تصویری تنها قابل تفسیر نیست.

۳-۱-۳ شبکه EfficientNet و کتابخانه timm

شبکه EfficientNet-B5^{۴۲} با مقیاس‌گذاری ترکیبی عمق، عرض و وضوح، خط پایه‌ی تصویری این پروژه است [۴] و پیاده‌سازی آن از کتابخانه‌ی timm^{۴۳} می‌آید. آموزش با آنتروپی متقاطع وزن‌دار کلاس انجام شد و انتخاب دور آموزش روی AUC اعتبارسنجی صورت گرفت تا آزمون در تصمیم‌ها وارد نشود.

۳-۱-۴ کتابخانه اندازه‌گیری عروقی

کتابخانه‌ی PVB^{۴۴} ستون‌های ویژگی هندسی و چگالی را از ماسک دودویی عروق استخراج می‌کند [۳]. این پژوهش از همان خانواده‌ی اندازه‌گیری استفاده می‌کند، اما مجموعه‌ی نهایی آن به پنج نشانگر محدود شد. جداساز عروقی این پروژه MANet^{۴۵} با رمزگذار ResNet34 است. ماسک مرجع متخصص برای داده‌ی این پروژه در دسترس نبود، پس صحت جداسازی در برابر مرز انسانی سنجیده نشد و کیفیت بالینی ماسک‌ها ادعا نمی‌شود.

۳-۱-۵ ارزیابی گروه‌آگاه در تصاویر پزشکی

در داده‌ی پزشکی واحد استقلال غالباً شخص یا معاینه است، نه فایل. تصویرهای یک نوزاد می‌توانند نور، زمینه و شکل ویژه‌ی همان شبکه را مشترک داشته باشند و ارزیابی گروه‌آگاه به مدل اجازه نمی‌دهد از این شباهت برای پیش‌بینی ظاهراً موفق موردی که قبلاً دیده است سود ببرد. این قاعده در تصویربرداری پزشکی استاندارد است و در این گزارش به‌عنوان شرط لازم ارزیابی به کار رفته، نه به‌عنوان نوآوری. در منبعی بدون شناسه‌ی بیمار، این قاعده فقط تا سطح شناسه‌ی در دسترس، یعنی معاینه، اعمال می‌شود.

^{۴۲} معماری تصویری با مقیاس‌گذاری هم‌زمان عمق، عرض و وضوح؛ معادل انگلیسی: EfficientNet-B5

^{۴۳} کتابخانه‌ی مدل‌های تصویری از پیش‌آموزش‌دیده برای PyTorch؛ معادل انگلیسی: timm

^{۴۴} جعبه ابزار پایتون برای استخراج ویژگی‌های هندسی عروق از ماسک؛ معادل انگلیسی: PVB

^{۴۵} شبکه‌ی جداسازی معنایی با توجه چندمقیاسه؛ معادل انگلیسی: MANet



۳-۱-۶ غربالگری پلاس در عمل

تشخیص Plus معمولاً در بخش مراقبت ویژه نوزادان با افتالموسکوپی غیرمستقیم انجام می‌شود و تأخیر یا کمبود متخصص خطر از دست رفتن پنجره‌ی درمان را بالا می‌برد. یک سامانه‌ی کمکی باید حساسیت بالا با اختصاصیت قابل قبول داشته باشد؛ در این پروژه آستانه‌ی یودن روی اعتبارسنجی این بدهستان را فقط به‌طور تقریبی متعادل می‌کند.

۳-۱-۷ سامانه‌های تحلیل تصویری پلاس

سامانه‌های پیشین تحلیل تصویری پلاس بر اندازه‌گیری صریح رگ استوارند و پیچ‌خوردگی و گشادشدگی را از تصویر استخراج می‌کنند [۶، ۷]. این خط پژوهشی به عملکرد بالایی رسیده است، پس فرض «بی‌ارزش بودن اندازه‌گیری صریح رگ» با شواهد سازگار نیست؛ پرسش این گزارش چیز دیگری است، آیا این اندازه‌ها روی یک بازنمایی آموخته‌شده اطلاعات مکمل اضافه می‌کنند یا نه. سه تفاوت میان این پروژه و آن سامانه‌ها تبیین‌کننده‌ی نتیجه‌ی این گزارش است؛ جدول ویژگی این پروژه ویژگی پهنای رگ یا گشادشدگی ندارد، شریان و ورید جدا نمی‌شوند، و ویژگی‌ها بر حسب پیکسل خام و روی کل تصویر محاسبه می‌شوند، نه با یک مقیاس آناتومیک در ناحیه‌ی قطب خلفی. کیفیت خود مرجع هم محدود است، چون توافق متخصصان بر تشخیص پلاس کامل نیست؛ این محدودیت سقف عملکرد هر مدل را تعیین می‌کند و دلیل دیگری است بر اینکه نتیجه‌ی این پروژه به‌عنوان پیش‌بینی برچسب ثبت‌شده در داده تفسیر شود، نه معادل تصمیم درمانی.

۳-۱-۸ جایگاه این کار

این پژوهش تعریف بالینی Plus را به یک مسئله‌ی رتبه‌بندی قابل اندازه‌گیری روی تصویر فوندوس تبدیل می‌کند، بدون ادعای جایگزینی معاینه. سهم افزایشی اندازه‌گیری صریح عروق در کنار یک بازنمایی تصویری یادگرفته‌شده و در کنار بازنمایی فضایی عروق سنجیده می‌شود. دستاورد این گزارش یک ادعای معماری نیست؛ یک پروتکل ارزیابی است که با قفل تقسیم، انتخاب مدل فقط با اعتبارسنجی، استنباط زوجی و سنجش انتقال به منبع کنار گذاشته اجرا شده است.



فصل ۴

تشریح موضوع و بیان مسئله

۴-۱ بیان مسئله

یک تصویر فوندوس همه‌ی اطلاعات لازم برای تصمیم درمانی را در اختیار نمی‌گذارد، اما می‌تواند برای رتبه‌بندی موارد مشکوک به کار رود. آنچه سنجیده می‌شود فقط توان رتبه‌بندی مدل‌ها در برابر برچسب ثبت‌شده در داده است، نه کاربرد بالینی، نه ایمنی و نه سودمندی در عمل. پرسش نخست این است که آیا اندازه‌گیری صریح عروق، ^{۴۶}Plus را از دو وضعیت دیگر جدا می‌کند و پرسش دوم این است که آیا افزودن همین اندازه‌گیری به یک بازنمایی تصویری آموخته‌شده رتبه‌بندی را بهتر می‌کند. پاسخ این دو لزوماً یکی نیست، پس اندازه‌گیری عروقی در دو سطح آزموده شد، پنج نشانگر اسکالر و بازنمایی فضایی نقشه‌ی عروق، و مقایسه‌ها روی تصاویر یکسان، یک تقسیم و یک معیار انجام گرفت.

۴-۲ چالش‌های کلیدی

نخستین چالش وابستگی نمونه‌هاست. تصاویر یک نوزاد شبیه هم‌اند و اگر میان آموزش و آزمون پخش شوند، مدل هویت چشم یا دستگاه را به جای نشانه‌ی بیماری به خاطر می‌سپارد. تقسیم این پروژه گروه‌محور است و هیچ گروهی در دو بخش نیست (جدول جدول ۶-۲). تعریف گروه اما در همه‌ی منابع یکسان نیست؛ در Plus و FARFUM-RoP در سطح بیمار و در فارابی در سطح معاینه، چون شناسه‌ی بیمار در آن منبع وجود نداشت. پس در فارابی، نبود هم‌پوشانی معاینه نبود هم‌پوشانی بیمار را اثبات نمی‌کند.

چالش دوم وابستگی به منبع تصویربرداری است. سه منبع ترکیب کلاس‌های بسیار متفاوتی دارند و منبع Plus هیچ مورد Pre-Plus ندارد؛ پس فقط معیار دودویی محدود Normal در برابر Plus با همان برچسب صریح گزارش می‌شود. این وابستگی اندازه‌گیری شد؛ جابه‌جایی بازنمایی‌ها میان هر منبع

^{۴۶}گشادشدگی و پیچ‌خوردگی پیش‌رونده‌ی عروق قطب خلفی؛ معادل انگلیسی: Plus



کنار گذاشته و منابع آموزش بدون استفاده از برچسب هدف محاسبه شد و Plus جابه‌جاشده‌ترین منبع بود (جدول جدول ۶-۹).

چالش سوم به کیفیت اندازه‌گیری نشانگرها مربوط است. نشانگرها از ماسک عروق می‌آیند و خطای جداسازی به خطای اندازه‌گیری تبدیل می‌شود. ماسک مرجع متخصص برای داده‌ی این پروژه در دسترس نبود، پس صحت جداسازی در برابر مرز انسانی سنجیده نشد و کنترل‌ها فقط سلامت فنی خروجی را تأیید می‌کنند؛ یک نشانگر ثابت هم در سه مرکز عدد یکسانی به دست نمی‌دهد. چالش چهارم انضباط آزمون است. اگر مدل، پیکربندی یا آستانه پس از دیدن آزمون تغییر کند، آن آزمون برآورد مستقلی از عملکرد نمی‌دهد. در این پروژه انتخاب مدل و آستانه فقط با اعتبارسنجی انجام شد و آزمون قفل‌شده برای نتیجه‌ی اصلی به کار رفت؛ تحلیل‌های بعدی روی همان تقسیم، بازتحلیل اکتشافی ثانویه‌اند.

۳-۴ رویکرد این پروژه

طراحی نهایی روی یک تقسیم استاندارد مشترک بنا شده است که در سطح گروه ساخته شد و هیچ گروه مشترکی میان بخش‌هایش نیست (جدول جدول ۶-۲). همه‌ی مدل‌ها روی همین تقسیم اجرا شدند تا اختلاف معیارها به مدل نسبت داده شود، نه به داده.

سه فرمول‌بندی ویژگی محور مقایسه‌اند؛ بازنمایی تصویری، تصویر به‌همراه بازنمایی فضایی عروق، و تصویر به‌همراه عروق و پنج نشانگر اسکالر. دو مرجع لازم هم اضافه می‌شود؛ نشانگرهای اسکالر به‌تنهایی و نقشه‌ی عروق به‌تنهایی، و نسخه‌ی الحاق زودهنگام نشانگرها برای همان پرسش ترکیب اجرا شد. این مجموعه پرسش «آیا اندازه‌گیری صریح عروقی اطلاعات دارد» را از پرسش «آیا افزودن آن به بازنمایی آموخته‌شده سود دارد» جدا می‌کند. استنباط بر بوت‌استرپ زوجی طبقه‌بندی‌شده استوار است و چون نمونه‌ها زوج‌اند، نتیجه به نابرابری اندازه‌ی کلاس‌ها حساس نیست.

انتقال با سه فولد منبع کنار گذاشته سنجیده شد؛ در هر فولد یک منبع کامل از آموزش، پیش‌پردازش و انتخاب مدل کنار گذاشته می‌شود و هیچ ویژگی بدون برچسبی از منبع هدف استفاده نمی‌شود. روی همین بستر، یک آزمایش ناوردایی دامنه‌ی شرطی به‌کلاس با ضرایب ثابت و بدون تنظیم روی منبع هدف اجرا شد؛ یک کنترل بی‌طرف در برابر همان شبکه به‌همراه متمایزکننده‌ی دامنه^{۴۷} و فاصله‌ی MMD^{۴۸} شرطی به‌کلاس. قابلیت پیش‌بینی هویت دامنه هم اندازه‌گیری شد و آخرین حلقه‌ی طراحی، تکرار پرسش

^{۴۷} شبکه‌ی عصبی تقابلی دامنه با لایه‌ی معکوس‌کننده‌ی گرادین؛ معادل انگلیسی: Domain-Adversarial Neural

Network

^{۴۸} فاصله‌ی بیشینه‌ی میانگین‌ها میان دو توزیع؛ معادل انگلیسی: Maximum Mean Discrepancy



عروقی با یک ستون فقرات تصویری دوم است.



فصل ۵

روش پیشنهادی و مدل سازی

۵-۱ داده، تقسیم استاندارد و ممیزی منشأ

هر سطر داده یک تصویر است، اما تصاویرهای یک بیمار یا یک معاینه مشاهده‌های مستقل نیستند؛ همین وابستگی مبنای ساخت تقسیم استاندارد قرار گرفت. جمعیت کانونی گزارش ۸۸۶۲ مورد کامل است و ترکیب آن به تفکیک منبع و کلاس در جدول ۵-۱ آمده است.

۵-۱-۱ جمعیت کانونی و منابع داده

داده از سه منبع تصویر فوندوس ساخته شد. ^{۴۹}Plus بزرگ‌ترین منبع است و فراداده‌ی دستگاه RetCam ^{۵۰} را همراه دارد. FARFUM-RoP ^{۵۱} و داده‌ی فارابی دو منبع دیگرند. برچسب‌های FARFUM-RoP از پرونده‌ی صفحه‌گسترده خوانده شد و در فارابی شناسه‌ی بیمار موجود نبود، پس شناسه‌ی یکتای معاینه جای آن را گرفت.

هشت مورد که در سه نشانگر فراکتالی مقدار NaN ^{۵۲} داشتند کنار گذاشته شدند و همه‌ی آن‌ها در بخش آموزش بودند. هیچ جایگزینی برای مقدارهای گم‌شده انجام نشد؛ بنابراین جمعیت گزارش، موارد کامل است. سهم هر منبع و هر کلاس در جدول ۵-۱ و شکل‌های شکل مربوط و شکل مربوط آمده است.

۵-۱-۲ فضای برچسب

سه برچسب Normal ^{۵۳}، Pre-Plus ^{۵۴} و Plus به سه کد صفر، یک و دو نگاشته می‌شوند. منبع Plus هیچ مورد Pre-Plus ندارد؛ پس برای این منبع نه مدل سه‌کلاسه معنا دارد و نه AUC ^{۵۵} سه‌کلاسه. در آن

^{۴۹}نام یکی از منابع تصویربرداری و نیز برچسب مرحله‌ی پلاس در رتینوپاتی نارس؛ معادل انگلیسی: Plus

^{۵۰}دستگاه تصویربرداری شبکه‌ی نوزادان؛ معادل انگلیسی: RetCam

^{۵۱}مجموعه‌ی عمومی تصاویر رتینوپاتی نارس؛ معادل انگلیسی: FARFUM-RoP

^{۵۲}مقدار عددی تعریف‌نشده؛ معادل انگلیسی: NaN

^{۵۳}وضعیت طبیعی شبکه؛ معادل انگلیسی: Normal


^{۵۴}وضعیت پیش از مرحله‌ی پلاس؛ معادل انگلیسی: Pre-Plus

^{۵۵}سطح زیر منحنی مشخصه‌ی عملکرد گیرنده؛ معادل انگلیسی: AUC




جدول ۵-۱: ترکیب جمعیت نهایی موارد کامل به تفکیک منبع تصویربرداری


منبع تصویر	گروه	Normal	Pre-Plus	Plus	درصد
فارابی	۱۶۰	۳۶۹	۴۵۲	۵۸۸	۱۵.۹
FARFUM-RoP	۶۸	۷۸۰	۴۷۸	۲۷۰	۱۷.۲
Plus	۱۸۶	۵۳۰۴	۰	۶۲۱	۶۶.۹
مجموع	۴۱۴	۶۴۵۳	۹۳۰	۱۴۷۹	۱۰۰.۰



شکل ۵-۱: توزیع کلاس در جمعیت نهایی به تفکیک منبع تصویربرداری (۸۸۶۲ تصویر، ۴۱۴ گروه). منبع Plus هیچ مورد Pre-Plus ندارد.



شکل ۵-۲: سهم هر منبع در جمعیت نهایی.



شکل ۵-۳: توزیع کلاس در تقسیم‌های آموزش، اعتبارسنجی و آزمون.



منبع فقط معیار محدود «Normal» در برابر «Plus» با برچسب صریح گزارش می‌شود و هرگز به جای مقدار سه کلاسه نمی‌نشیند. این تفکیک لازم است، زیرا ممکن است مدلی دو گروه منفی را با هم اشتباه بگیرد و همچنان Plus را درست رتبه‌بندی کند.

۳-۱-۵ تقسیم استاندارد

شمارش هر بخش و هر کلاس در جدول ۲-۵ و شکل شکل مربوط آمده است. تخصیص گروه‌ها به سه بخش با یک رویه‌ی قطعی انجام می‌شود؛ هیچ گروهی در بیش از یک بخش قرار نمی‌گیرد و اجرای دوباره‌ی همان رویه همان تقسیم را می‌سازد. بخش آموزش بیشترین سهم را از منبع Plus دارد و فارابی کمترین سهم را.

جدول ۲-۵: تقسیم گروه‌محور استاندارد جمعیت موارد کامل

تقسیم	N	Normal	Pre-Plus	Plus	گروه
آموزش	۶۲۰۳	۴۴۹۰	۶۵۰	۱۰۶۳	۲۹۰
اعتبارسنجی	۱۳۲۸	۹۸۱	۱۴۰	۲۰۷	۶۲
آزمون	۱۳۳۱	۹۸۲	۱۴۰	۲۰۹	۶۲
مجموع	۸۸۶۲	۶۴۵۳	۹۳۰	۱۴۷۹	۴۱۴

تعریف گروه میان منابع یکسان نیست. در Plus و FARFUM-RoP گروه بر پایه‌ی بیمار ساخته شده است، اما در فارابی شناسه‌ی بیمار در دسترس نبود و گروه بر پایه‌ی معاینه تعریف شد. نتیجه‌ی مستقیم این تفاوت آن است که برای فارابی، نبود هم‌پوشانی در سطح معاینه تأیید شده است و استقلال در سطح بیمار اثبات‌نشده باقی می‌ماند؛ به همین دلیل در سراسر این گزارش فقط عبارت «نبود هم‌پوشانی در سطح شناسه‌ی گروه قابل دسترس» به کار می‌رود و هیچ ادعای مطلقی فراتر از همین سطح مطرح نمی‌شود.

۴-۱-۵ جایگاه آزمون استاندارد در برابر تحلیل‌های ثانویه

تقسیم استاندارد پیش از این برای مقایسه‌ی اصلی به کار رفته و همه‌ی پارامترهای قابل انتخاب با بخش اعتبارسنجی تعیین شده‌اند. بنابراین هر تحلیل دیگری که روی همان آزمون اجرا شده باشد، تحلیل مجدد اکتشافی ثانویه روی یک تقسیم قفل‌شده است و آزمون تازه محسوب نمی‌شود. این تفکیک در



سراسر گزارش حفظ می‌شود و مستندسازی این تحلیل‌ها به معنای تأیید دوباره‌ی آن‌ها نیست. هر عدد گزارش شده به همین تقسیم، به بذر پروژه و به اثر انگشت پیکربندی متناظر خود گره خورده است.

۵-۱-۵ تاریخچه‌ی توسعه، غیرقطعی

مراحل پیشین توسعه‌ی این پروژه بخشی از تحلیل این گزارش نیست و هیچ عددی از آن‌ها در فصل‌های روش و نتایج نقل نمی‌شود. مرجع همه‌ی عددهای گزارش، مصنوعات تثبیت‌شده‌ی نسخه‌ی نهایی پروژه است.

۵-۲ جداسازی عروق و پنج نشانگر نهایی

مسیر نشانگری تصویر را مستقیماً به طبقه‌بند نمی‌دهد. برای هر تصویر یک نقشه‌ی احتمال عروقی ساخته می‌شود، آستانه‌گذاری از آن یک ماسک دودویی می‌سازد و اندازه‌گیری‌ها از همان ماسک استخراج می‌شوند؛ پس معماری جداساز و آستانه‌ی ماسک بخشی از تعریف داده‌ی ورودی این مسیرند.

۵-۲-۱ جداساز عملیاتی

جداساز عملیاتی این پروژه شبکه‌ی ^{۵۶}MANet با رمزگذار ^{۵۷}ResNet34 است. تصویر فوندوس به این شبکه داده می‌شود و خروجی احتمال آن با آستانه‌گذاری به ماسک دودویی تبدیل می‌شود. ماسک‌های مصرفی مسیر عروقی از مجموعه‌ی تثبیت‌شده‌ی پروژه می‌آیند تا بازتولید نتایج به یک نسخه‌ی مشخص گره بخورد. بازیابی ماسک فقط نام دقیق ثبت‌شده را می‌پذیرد و هیچ بازگشت تقریبی در آن راه ندارد.

۵-۲-۲ پنج نشانگر نهایی


مسیر نشانگری دقیقاً پنج عدد اسکالر تولید می‌کند. `vessel_density_fov` نسبت پیکسل‌های عروقی به مساحت محتوا در میدان دید است و `skel_density_fov` همان نسبت را برای پیکسل‌های اسکلت (خط مرکزی) عروق می‌سنجد. سه نشانگر دیگر، `fractal_d0`، `fractal_d1` و `fractal_d2`، ابعاد فراکتالی مرتبه‌ی صفر، یک و دو هستند که از تحلیل چندفراکتالی ماسک عروق به دست می‌آیند. هر پنج نشانگر روی میدان دید تعریف شده‌اند، نه روی ناحیه‌ای بسته به دیسک بینایی؛ همین تعریف مقایسه‌ی مستقیم آن‌ها را با سامانه‌هایی که ناحیه‌ی بررسی را با قطر دیسک می‌سنجد محدود می‌کند. تعریف اندازه‌گیری

^{۵۶}نام معماری جداساز عروق؛ معادل انگلیسی: MANet

^{۵۷}شبکه‌ی عصبی باقیمانده با ۳۴ لایه؛ معادل انگلیسی: ResNet34



در نسخه‌ی تثبیت‌شده‌ی پروژه مخرج نشانگرهای پوشش را برابر مساحت محتوا در میدان دید می‌گذارد و همین تعریف مقیاس اندازه‌گیری را از حاشیه‌های بی‌محتوا جدا می‌کند.



شکل ۴-۵: خط لوله‌ی ساخت پنج نشانگر اسکالر از تصویر فوندوس و نقشه‌ی عروق.

۳-۲-۵ محدودیت اعتبارسنجی جداسازی

ماسک مرجع متخصص برای این جمعیت در دسترس نیست؛ بنابراین هیچ معیار هم‌پوشانی نوع Dice^{۵۸} روی داده‌ی خود این پروژه محاسبه نشده است و درباره‌ی صحت بالینی جداسازی در این جمعیت ادعایی مطرح نمی‌شود.

این شکاف تفسیر نتیجه‌ی نشانگرهای اسکالر را محدود می‌کند و دو علت ممکن را از هم جدا نمی‌کند. یک احتمال آن است که پنج عدد اسکالر واقعاً اطلاعات کمتری از بازنمایی یادگرفته‌شده‌ی شبکه حمل می‌کنند؛ احتمال دیگر آن است که کیفیت ماسک و اندازه‌گیری برای این جمعیت محدود باشد و بخشی از ضعف نتیجه از همین جا بیاید. طرح آزمایش‌های این گزارش توان جدا کردن این دو علت را ندارد و قضاوت میان آن‌ها به ارزیابی جداسازی با ماسک مرجع نیاز دارد. آنچه داده نشان می‌دهد این است که در رژیم‌های آزمون‌شده، افزودن این پنج نشانگر افزایش پشتیبانی‌شده‌ای فراتر از بازنمایی یادگرفته‌شده ایجاد نکرد.

^{۵۸}معیار هم‌پوشانی دو ماسک دودویی؛ معادل انگلیسی: Dice



۳-۵ پروتکل ارزیابی و آزمایش‌های اکتشافی

مقایسه‌ی مدل‌ها فقط زمانی معنا دارد که تقسیم داده، تعریف معیار و لحظه‌ی استفاده از آزمون در همه‌ی آن‌ها یکسان باشد. این بخش چارچوبی را تعریف می‌کند که همه‌ی عده‌های گزارش از آن بیرون آمده‌اند.

۱-۳-۵ سه رژیم ارزیابی

رژیم نخست، تقسیم استاندارد قفل‌شده است و مقایسه‌ی اصلی گزارش را می‌سازد؛ مدل‌های مرجع روی بخش آموزش می‌آموزند، انتخاب مدل و آستانه روی بخش اعتبارسنجی انجام می‌شود و ارزیابی نهایی یک بار روی بخش آزمون صورت می‌گیرد. رژیم دوم، سه فولد منبع کنار گذاشته است و به پرسش انتقال پاسخ می‌دهد؛ هر بار یک منبع کامل کنار گذاشته می‌شود و مدل فقط روی دو منبع دیگر برازش می‌یابد. منبع کنار گذاشته در برازش، پیش‌پردازش، انتخاب مدل و توقف زودهنگام هیچ سهمی ندارد، حتی به صورت ویژگی بدون برچسب. رژیم سوم، آزمایش ناوردایی دامنه است و به این پرسش پاسخ می‌دهد که آیا هم‌ترازی شرطی به کلاس، انتقال به منبع دیده‌نشده را بهتر می‌کند یا نه.

این سه رژیم سه پرسش متفاوت را می‌سنجند و عده‌هایشان هرگز در یک ستون یا یک میانگین جمع نمی‌شوند؛ تفاوت جمعیت‌ها هم اجازه‌ی چنین تجمعی نمی‌دهد. پس از مقایسه‌ی اصلی، چند گروه مدل دیگر روی همان تقسیم قفل‌شده اجرا شد که پرسش‌هایشان جدا از مقایسه‌ی اصلی مطرح می‌شود و هیچ‌یک جای نتیجه‌ی اصلی را نمی‌گیرد.

۲-۳-۵ بوت‌استرپ زوجی طبقه‌محور

هر مقایسه‌ی زوجی در این گزارش با یک رویه‌ی واحد انجام شده است. روی پیش‌بینی‌های دو مدل برای همان تصویرها، ده هزار بازنمونه‌گیری با بذر ثابت تولید می‌شود و در هر تکرار، نمونه‌گیری درون هر کلاس واقعی جداگانه صورت می‌گیرد تا کلاس‌های کوچک در نمونه‌های بازتولیدی حضور داشته باشند. هر دو مدل روی یک مجموعه‌ی بازنمونه‌برداری شده‌ی یکسان ارزیابی می‌شوند، پس تفاضل‌ها زوجی‌اند. بازه‌ی اطمینان و مقدار احتمال دودوسویه با مرکز صفر از صدک‌های همین توزیع خوانده می‌شوند. این رویه عیناً برای همه‌ی مقایسه‌های زوجی گزارش و در هر سه رژیم به کار رفته است.



۳-۳-۵ معیارهای گزارش

پنج معیار گزارش می‌شوند. AUC ماکروی یک‌در برابر بقیه^{۵۹}، دقت متعادل و F1 ماکرو بزرگ‌تر بهتر هستند و امتیاز Brier^{۶۰} و ECE^{۶۱} کوچک‌تر بهتر. هیچ امتیاز ترکیبی ساخته نشده و مدل‌ها با یک عدد واحد رتبه‌بندی نمی‌شوند، زیرا رتبه‌بندی، تصمیم و کالیبراسیون سه خاصیت متفاوت‌اند و یک میانگین وزنی تفاوت میان آن‌ها را پنهان می‌کند. دقت متعادل بالا به تنهایی برتری نیست؛ در مدل‌هایی که تابع زیانشان کلاس اقلیت را تهاجمی پیش‌بینی می‌کند، دقت متعادل می‌تواند بالا برود در حالی که AUC، F1 ماکرو و کالیبراسیون بدتر می‌شوند و این حالت صریحاً تفاوت گزارش می‌شود.

۴-۳-۵ ارزیابی محدود منبع Plus

در منبع Plus هیچ موردی با برچسب Pre-Plus وجود ندارد. برای این منبع، مدل سه‌کلاسه و AUC سه‌کلاسه تعریف شده نیستند و هیچ مقداری هم به جای آن‌ها گذاشته نمی‌شود. آنچه گزارش می‌شود AUC دودویی محدود «Normal در برابر Plus» است که در متن و در همه‌ی شکل‌ها با همین برچسب صریح می‌آید و در هیچ جدول یا شکل مشترکی با مقدارهای سه‌کلاسه در یک ستون قرار نمی‌گیرد. امتیاز این معیار از همان احتمال کلاس Plus می‌آید تا با بقیه‌ی گزارش هم‌تعریف باشد.

۵-۳-۵ قفل آزمون و پیکربندی تثبیت‌شده

همه‌ی پارامترهای قابل انتخاب، از جمله معماری سر، نرخ یادگیری، پیکربندی ابرپارامتر و آستانه‌ی تصمیم، فقط با بخش اعتبارسنجی انتخاب شده‌اند. مجموعه‌ی آزمون پس از تثبیت همه‌ی این انتخاب‌ها یک بار خوانده شده و یک سند تثبیت نوشته شده است که فهرست پارامترهای قفل‌شده، اثر انگشت تقسیم و اثر انگشت مصنوعات را در بر می‌گیرد. آستانه‌ی تصمیم با شاخص Youden^{۶۲} روی اعتبارسنجی انتخاب و سپس بدون تغییر روی آزمون اعمال می‌شود؛ این آستانه خاصیت ثابت بیماری نیست و با هزینه‌ی خطا در مرکز دیگر تغییر می‌کند.

XGBoost^{۶۳} سر پایین‌دستی همه‌ی مدل‌هایی است که روی بازنمایی^{۶۴} تثبیت‌شده آموزش می‌بینند و همه‌ی آن‌ها یک پیکربندی یکسان دارند که مقادیر دقیق آن در سند تثبیت پروژه ثبت شده است.

^{۵۹} میانگین سطح زیر منحنی برای هر کلاس در برابر بقیه‌ی کلاس‌ها؛ معادل انگلیسی: macro one-vs-rest AUC

^{۶۰} میانگین مربع خطای احتمال پیش‌بینی؛ معادل انگلیسی: Brier score

^{۶۱} خطای کالیبراسیون انتظاری؛ معادل انگلیسی: Expected Calibration Error

^{۶۲} شاخص انتخاب آستانه بر پایه‌ی حساسیت و ویژگی؛ معادل انگلیسی: Youden index

^{۶۳} پیاده‌سازی درخت‌های تقویت‌شده با گرادیان؛ معادل انگلیسی: XGBoost

^{۶۴} بردار عددی فشرده‌ی ساخته‌شده توسط شبکه از تصویر؛ معادل انگلیسی: embedding



یکسان بودن این پیکربندی عمدی است، زیرا تغییر ابرپارامتر برای هر مدل، مقایسه را به مقایسه‌ی تنظیم کردن تبدیل می‌کند و سهم واقعی بازنمایی را پنهان می‌گذارد؛ بنابراین تفاوت‌های گزارش شده میان مدل‌های بازنمایی به ورودی آن‌ها مربوط است، نه به سر پایین‌دستی. شکل مربوط

۵-۳-۶ مرور

جریان پردازش

خط لوله دو مسیر موازی روی یک تصویر مشترک دارد. یک تصویر فوندوس استاندارد هم به رمزگذار تصویری و هم به مسیر اندازه‌گیری عروقی داده می‌شود. مسیر نخست یک بردار تصویری و مسیر دوم یک بردار عروقی به همراه پنج عدد اسکالر تولید می‌کند. مدل‌های ترکیب این خروجی‌ها را کنار هم می‌گذارند و یک سر طبقه‌بندی سه کلاسه روی آن‌ها آموزش می‌بیند؛ ورودی و بُعد هر مدل در **جدول ۵-۳** آمده است.

شاخه‌ی تصویری تصویر RGB^{۶۵} را با آماره‌های استاندارد پیش‌آموزش نرمال می‌کند و بدنه‌ی آن EfficientNet-B5^{۶۶} است. تقویت داده عمداً محافظه‌کارانه و هندسی است و به چرخش محدود، وارونگی افقی و برش جزئی بسنده می‌کند، چون نشانگرهای عروقی و ظاهر شبکیه به رنگ و کنتراست حساس‌اند. خروجی این شاخه دو مصرف دارد؛ در مدل B به یک طبقه‌بند خطی می‌رود و در مدل B-emb و مدل‌های ترکیبی تثبیت‌شده ذخیره می‌شود تا سر پایین‌دستی روی آن آموزش ببیند.

شاخه‌ی عروقی ماسک دودویی تثبیت‌شده‌ی پروژه را با درون‌یابی نزدیک‌ترین همسایه به وضوح ورودی می‌رساند، چون درون‌یابی خطی روی ماسک دودویی پیکسل‌هایی با مقدار میانی می‌سازد که نه عروق‌اند و نه پس‌زمینه. رمزگذار این شاخه EfficientNet-B4^{۶۷} است و بردار عروقی می‌دهد؛ معماری سبک‌تر عمدی است، چون ورودی این شاخه بافت رنگی ندارد و ظرفیت بیشتر توجیه روشنی ندارد.

مدل‌های بازنمایی همگی سر XGBoost یکسان دارند و ورودی هر مدل، الحاق همان بازنمایی‌های **جدول ۵-۳** است. چون رمزگذارها تثبیت‌شده‌اند، بازنمایی هر تصویر یک بار استخراج و ذخیره می‌شود؛ این طراحی مقایسه را تکرارپذیر می‌کند و امکان می‌دهد سهم هر بلوک ورودی جداگانه خوانده شود. مدل F ترکیب وزنی دیرهنگام E و D است، اما ضریب اختلاط آن روی مرز شبکه اشباع شد و خروجی احتمالش با مدل B-emb یکسان درآمد؛ به همین دلیل نتیجه‌ی مستقلی برای آن خوانده نمی‌شود.

^{۶۵} تصویر رنگی سه کاناله؛ معادل انگلیسی: RGB

^{۶۶} معماری تصویری با مقیاس‌گذاری هم‌زمان عمق، عرض و وضوح؛ معادل انگلیسی: EfficientNet-B5

^{۶۷} معماری تصویری هم‌خوانده‌ی EfficientNet-B5 با ظرفیت کمتر؛ معادل انگلیسی: EfficientNet-B4




جدول ۵-۳: ورودی و ابعاد مدل‌های اصلی

مدل	ورودی	بُعد
A	پنج نشانگر اسکالر	۵
B	تصویر RGB و طبقه‌بند خطی روی EfficientNet-B5	۲۰۴۸
B-emb	بازنمایی تصویری تثبیت‌شده به XGBoost	۲۰۴۸
C	بازنمایی تصویری به همراه پنج نشانگر	۲۰۵۳
D	ماسک عروق و طبقه‌بند خطی روی EfficientNet-B4	۱۷۹۲
E	بازنمایی تصویری به همراه عروقی	۳۸۴۰
G	تصویری، عروقی و پنج نشانگر	۳۸۴۵
H	دو رمزگذار تثبیت‌شده، تعامل و MLP	۵۱۲+۵۱۲
I	مانند H به همراه شاخه‌ی نشانگری	۳۲ و ۵۱۲+۵۱۲
L	توجه نرم دوستون فقرات ResNet50 و EfficientNet-B4	۱۰۲۴
M0	بازنمایی توجهی به XGBoost	۱۰۲۴
M1	بازنمایی توجهی به همراه عروقی	۲۸۱۶



۷-۳-۵ مدل‌های ترکیب عصبی و FiLM

مدل H دو رمزگذار تثبیت‌شده را نگه می‌دارد و بازنمایی‌های هر شاخه را به یک بلوک تعامل و سپس یک MLP^{۶۸} می‌دهد؛ مدل I همان ساختار را با یک شاخه‌ی کوچک برای پنج نشانگر تکمیل می‌کند. مدل‌های J0 و J1 یک جفت کنترل هم‌تا می‌سازند؛ J0 فقط بازنمایی‌های تثبیت‌شده را به یک MLP کنترل می‌دهد و J1 روی شاخه‌ی عروقی همان ساختار یک تعدیل FiLM^{۶۹} کران‌دار اضافه می‌کند. کران‌گذاری و مقدار اولیه‌ی نزدیک هم‌انی عمدی است، تا بدترین حالت FiLM نزدیک به هم‌انی بماند و نتواند بازنمایی عروقی را در آغاز آموزش تخریب کند. مدل L دو رمزگذار ResNet50 و EfficientNet-B4 را با توجه نرم ترکیب می‌کند و مدل‌های M0 و M1 روی بازنمایی تثبیت‌شده‌ی آن ساخته می‌شوند. معماری این مدل‌ها در شکل مربوط آمده است.



شکل ۵-۵: معماری و ابعاد ورودی مدل‌های اصلی.

^{۶۸} شبکه‌ی عصبی چندلایه‌ی پیش‌خور؛ معادل انگلیسی: Multi-Layer Perceptron
^{۶۹} تعدیل خطی ویژگی با پارامترهای تولیدشده از ورودی شرطی؛ معادل انگلیسی: Feature-wise Linear Modulation



۵-۳-۸ آموزش مدل‌های عصبی

آموزش این مدل‌ها دو مرحله دارد؛ در مرحله‌ی نخست رمزگذارها تثبیت شده می‌مانند و فقط سر آموزش می‌بینند و در مرحله‌ی دوم بخشی از بدنه‌ی رمزگذارها همراه با سر باز می‌شود. بهینه‌ساز AdamW و زمان‌بند OneCycleLR در PyTorch به کار رفت. در این جمعیت، بخش بازشده‌ی آموزش سهمی در بهبود عملکرد اعتبارسنجی نداشت؛ خطای آموزش پایین می‌رفت در حالی که خطای اعتبارسنجی بالا می‌رفت. علت محتمل آن است که شمار نمونه‌های آموزش برای ظرفیت این سرها کم است، و این مشاهده یک محدودیت طرح است، نه نتیجه‌ی مثبت برای آموزش مرحله‌ای.

۵-۳-۹ مدل ناوردایی دامنه

مدل K0 کنترل بی‌طرف دامنه است؛ یک سر عصبی کوچک روی بازنمایی تثبیت شده‌ی تصویری و عروقی. مدل K1 همان ساختار را با یک متمایزکننده‌ی دامنه که گرادیان آن با لایه‌ی معکوس‌کننده‌ی گرادیان^{۷۰} برمی‌گردد و یک جمله‌ی MMD^{۷۱} شرطی به کلاس گسترش می‌دهد و می‌توان آن را نمونه‌ای DANN^{۷۲} شرطی به کلاس دانست. ضرایب هر دو جمله ثابت‌اند و روی منبع کنارگذاشته تنظیم نشدند، زیرا تنظیم ضریب روی هدف همان اطلاعاتی را وارد می‌کند که این رژیم می‌خواهد از آن پرهیز کند. این آزمایش فقط یک بار و روی یک طرح اجرا شد و ادعای عمومی درباره‌ی هم‌ترازی دامنه از آن گرفته نمی‌شود.

۵-۳-۱۰ شبه‌کد

شبه‌کد زیر مرز میان آموزش، انتخاب مدل و ارزیابی نهایی را فشرده می‌کند.

برنامه ۱: پروتکل آموزش و ارزیابی مدل‌های اصلی

Input: fundus images, labels, source IDs, group IDs

Build the canonical grouped split

Assert: no group appears in more than one split part

For each image:

resize the RGB image and normalise with the pretraining statistics

take the frozen binary vessel mask, resize with nearest neighbour

^{۷۰}لایه‌ای که علامت گرادیان را در گذر از متمایزکننده‌ی دامنه برمی‌گرداند؛ معادل انگلیسی: Gradient Reversal Layer

^{۷۱}فاصله‌ی بیشینه‌ی میانگین‌ها بین دو توزیع؛ معادل انگلیسی: Maximum Mean Discrepancy

^{۷۲}شبکه‌ی عصبی تقابلی دامنه؛ معادل انگلیسی: Domain-Adversarial Neural Network



```
compute the five scalar biomarkers
```

```
Freeze both encoders and cache the image and vessel embeddings
```

```
Train the shared XGBoost head on each input combination
```

```
Select every model and its threshold on validation only
```

```
Write the freeze record, then read the test split once
```

```
Report the five metrics with the paired class-stratified bootstrap
```

```
Run the three source-held-out folds and the invariance pair separately
```

۴-۵ آزمون‌های خودکار و محافظ‌های یکپارچگی

آزمون‌های خودکار نرم‌افزاری بخشی از روش‌شناسی این پروژه‌اند، زیرا تغییر بی‌صدای تقسیم یا بازشدن مجموعه‌ی آزمون هنگام انتخاب معماری، معنای عدد گزارش‌شده را عوض می‌کند. این آزمون‌ها نبود هم‌پوشانی گروهی در تقسیم را کنترل می‌کنند، از خوانده‌شدن دوباره‌ی مجموعه‌ی آزمون جلوگیری می‌کنند و مسیرهای بازیابی ماسک را می‌سنجند. عبور از این آزمون‌ها سازگاری اجرای نرم‌افزار را نشان می‌دهد و جای ارزیابی کیفیت پیش‌بینی را نمی‌گیرد.

برای هر مصنوع پروژه یک اثر انگشت SHA-256^{۷۳} ثبت می‌شود؛ فهرست هر مرحله، اثر انگشت همه‌ی فایل‌های خروجی آن را در لحظه‌ی تثبیت نگه می‌دارد. پیش از اجرای هر تحلیل، اثر انگشت مصنوعات تثبیت‌شده‌ی مراحل پیشین با همان فهرست مقایسه می‌شود و تنها در صورت یکسانی، تحلیل ادامه می‌یابد. این کنترل همان چیزی است که اجازه می‌دهد تحلیل‌های ثانویه روی آزمون قفل‌شده به مصنوعات ثابت ارجاع بدهند.

^{۷۳}تابع اثرانگشت رمزنگاری‌شده برای ثبت یکتای محتوای یک پرونده؛ معادل انگلیسی: SHA-256



فصل ۶

آزمایش‌ها و تحلیل نتایج

نتایج این فصل از سه رژیم ارزیابی می‌آید که جمعیت و واحد شمارش‌شان یکی نیست و عددهایشان با هم جمع نمی‌شوند. رژیم نخست تقسیم گروه‌محور استاندارد قفل‌شده است، رژیم دوم فولدهای منبع‌کنارگذاشته که در هر فولد یک مرکز تصویربرداری کامل از برازش بیرون می‌ماند، و رژیم سوم آزمایش ناوردایی دامنه. تفاوت این سه در سطح سنجش است، نه در کیفیت اجرا. تحلیل‌های این فصل روی تقسیم گروه استاندارد قفل‌شده انجام شده‌اند. جز مقایسه‌ی اصلی، بقیه‌ی تحلیل‌ها ثانویه و اکتشافی‌اند و بار استنباطی یکسانی با آن ندارند. جدول زیر گروه‌های آزمایشی این فصل و کار هر گروه را کنار هم می‌گذارد؛ معیار مشترک سطرهای تقسیم کانونی سطح زیر منحنی مشخصه‌ی عملکرد گیرنده است و مقدار دقیق هر تفاضل در جدول‌های همین فصل آمده است.

۱-۶ نتایج آزمون کانونی قفل‌شده

این زیربخش نتیجه‌ی رژیم نخست است، مقایسه‌ی مدل‌های اصلی روی تقسیم گروه‌محور استاندارد قفل‌شده. انتخاب مدل و آستانه فقط روی اعتبارسنجی انجام شد و پیکربندی طبقه‌بند در همه‌ی مدل‌های بازنمایی یکسان ماند.

۱-۱-۶ ترکیب جمعیت و تقسیم استاندارد

جمعیت نهایی موارد کامل از سه منبع تصویربرداری می‌آید. منبع Plus هیچ مورد Pre-Plus ندارد، پس سطح زیر منحنی سه‌کلاسه برای آن تعریف‌نشده است و ارزیابی آن به معیار محدود «Normal» در برابر Plus» با برچسب صریح محدود می‌ماند. این مقدار جانشین مقدار سه‌کلاسه نمی‌شود و شمار هر منبع و کلاس در جدول شکل مربوط آمده است.

تقسیم گروه‌محور است و هیچ گروهی در بیش از یک تقسیم دیده نمی‌شود. تعریف گروه در Plus و FARFUM-RoP بر پایه‌ی بیمار و در فارابی بر پایه‌ی معاینه است، چون شناسه‌ی بیمار در فارابی در



جدول ۶-۱: گروه‌های آزمایشی فصل ششم، هدف و نتیجه‌ی اصلی هر گروه. سطرهای تقسیم‌بندی کانونی روی آزمون قفل‌شده و دو سطر دیگر روی جمعیت همان منبع کنار گذاشته محاسبه شده‌اند.


گروه آزمایشی	هدف	نتیجه‌ی اصلی
مقایسه‌ی اصلی کانونی (Task 6)	سنجش سه مسیر نشانگری، تصویری و بازنمایی روی یک تقسیم	بازنمایی تصویری بالاتر از رمزگذار تصویری؛ نشانگرها تفاوت ناچیز؛ عروق بهتر.
استنباط زوجی (Task 7)	پشتیبانی آماری هر افزایش با فاصله‌ی اطمینان	افزایش عروقی پشتیبانی شد؛ دو افزایش نشانگری نه.
بازنمایی فضایی عروق (Task 8/8B)	افزودن نمایش فضایی نقشه‌ی عروق به بازنمایی تصویری	ترکیب تصویر و عروق بهترین رتبه‌بندی و کیفیت احتمال؛ نقشه‌ی عروق تنها ضعیف‌تر از مسیرهای تصویری.
ترکیب مشترک یادگیرنده (Task 9)	آموزش سر مشترک دو رمزگذار تثبیت‌شده، با و بدون نشانگر	ترکیب مشترک پایین‌تر از ترکیب الحاقی؛ شاخه‌ی نشانگری کاهش پشتیبانی‌شده داد؛ ثانویه.
شرطی‌سازی نشانگری (Task 10)	کنترل تثبیت‌شده در برابر تعدیل کران‌دار شاخه‌ی عروقی	تعدیل همانی؛ تفاضل رتبه‌بندی شامل صفر؛ بهبود کالبراسیون از نشانگرها نیست؛ ثانویه.
انتقال به منبع دیده‌نشده (Task 11)	کنار گذاشتن یک مرکز تصویربرداری در هر فولد	افزایش عروقی در دو فولد سه‌کلاسه پشتیبانی شد و در فولد محدود Plus نه؛ افزایش نشانگری در هیچ فولد نه.
ناوردایی دامنه (Task 12)	هم‌ترازی دو دامنه‌ی آموزشی با متمایزکننده‌ی دامنه	هم‌ترازی بهبود عملکردی نداد؛ هویت دامنه قابل پیش‌بینی ماند.
استواری معماری نتیجه‌ی عروقی (Task 13)	آزمودن نتیجه‌ی عروقی با ستون فقرات تصویری متفاوت	کنترل فقط تصویری ضعیف‌تر از بازنمایی اصلی؛ افزودن عروق در همان خانواده بهبود داد؛ ثانویه.




جدول ۶-۲: ترکیب جمعیت نهایی موارد کامل به تفکیک منبع تصویربرداری

منبع تصویر	گروه	Normal	Pre-Plus	Plus	درصد کل
فارابی	۱۶۰	۳۶۹	۴۵۲	۵۸۸	۹.۱۵
فارفوم	۶۸	۷۸۰	۴۷۸	۲۷۰	۲.۱۷
Plus	۱۸۶	۵۳۰۴	۰	۶۲۱	۹.۶۶
مجموع	۴۱۴	۶۴۵۳	۹۳۰	۱۴۷۹	۰.۱۰۰


منبع Plus هیچ مورد Pre-Plus ندارد؛ بنابراین سنجی سه کلاسه برای آن تعریف نشده است و در تمامی تحلیل‌ها فقط ارزیابی محدود «Normal در برابر Plus» با برچسب صریح گزارش می‌شود.




شکل ۶-۱: توان رتبه‌بندی مدل‌های اصلی روی آزمون کانونی (۱۳۳۱ تصویر). محور افقی از ۶۰.۰ آغاز شده و مقیاس مطلق برچسب‌گذاری شده است.




شکل ۶-۲: سطح زیر منحنی چند کلاسه‌ی مدل‌های اصلی روی آزمون کانونی (۱۳۳۱ تصویر). بزرگ‌تر بهتر است.




شکل ۶-۳: دقت متعادل مدل‌های اصلی روی آزمون کانونی (۱۳۳۱ تصویر). بزرگ‌تر بهتر است.




شکل ۴-۶: افیک ماکروی مدل‌های اصلی روی آزمون کانونی (۱۳۳۱ تصویر). بزرگ‌تر بهتر است.




شکل ۵-۶: امتیاز Brier مدل‌های اصلی روی آزمون کانونی (۱۳۳۱ تصویر). کوچک‌تر بهتر است.




شکل ۶-۶: خطای کالیبراسیون انتظاری با پانزده سبد هم‌عرض برای مدل‌های اصلی روی آزمون کانونی (۱۳۳۱ تصویر). کوچک‌تر بهتر است.




شکل ۶-۷: سطح زیر منحنی کلاس به‌صورت یک‌در برابر بقیه روی آزمون کانونی (۱۳۳۱ تصویر).



شکل ۶-۸: سطح زیر منحنی کلاس به صورت یک در برابر بقیه روی آزمون کانونی (۱۳۳۱ تصویر).



شکل ۶-۹: سطح زیر منحنی کلاس به صورت یک در برابر بقیه روی آزمون کانونی (۱۳۳۱ تصویر).



شکل ۶-۱۰: سطح زیر منحنی هر کلاس به صورت یک‌دربرابر بقیه روی آزمون کانونی (۱۳۳۱ تصویر).

دسترس نبود؛ پس نبود هم‌پوشانی معاینه اثبات نبود هم‌پوشانی بیمار نیست. آزمون کانونی ۱۳۳۱ تصویر دارد و شمار هر تقسیم و کلاس در جدول ۵-۲ آمده است.

۲-۱-۶ عملکرد مدل‌های اصلی


نشانگرهای اسکالر بالاتر از سطح شانس می‌ایستند و از هر مسیر تصویری پایین‌ترند. رمزگذار EfficientNet-B5 روی تصویر RGB با طبقه‌بند خطی کمی ضعیف‌تر از همان رمزگذار با طبقه‌بند جدولی می‌ماند و مقدار دقیق معیارها در جدول شکل مربوط آمده است.

افزودن پنج نشانگر به بازنمایی تصویری تقریباً هیچ تغییری در رتبه‌بندی نمی‌دهد؛ افزودن بازنمایی عروقی آن را بهتر می‌کند و افزودن هر دو بهترین مقدار را می‌سازد. شبکه‌ی نقشه‌ی عروقی به‌تنهایی از نشانگرهای اسکالر بالاتر و از هر مسیر تصویری پایین‌تر است.


بهترین سطح زیر منحنی و دقت متعادل و F1 ماکرو به ترکیب تصویر و عروق و نشانگرها می‌رسد، ولی بهترین کالیبراسیون به رمزگذار تصویری با طبقه‌بند خطی تعلق دارد؛ یک عدد تصویر کامل مدل را نمی‌دهد.

۳-۱-۶ نمای چندمعیاره و رفتار هر کلاس


AUC و دقت متعادل و F1 ماکرو بزرگ‌تر بهترند و Brier و ECE کوچک‌تر بهتر؛ شکل زیر هر معیار را جدا نشان می‌دهد و هیچ امتیاز ترکیبی ساخته نشده است.




شکل ۶-۱۱: ماتریس درهم‌ریختگی مدل نشانگرهای اسکالر روی آزمون کانونی. سطرها کلاس واقعی و ستون‌ها کلاس پیش‌بینی شده‌اند؛ هر سطر به صد درصد جمع می‌شود و شمارش خام در پرانتز آمده است.




شکل ۶-۱۲: ماتریس درهم‌ریختگی مدل بازنمایی تصویری روی آزمون کانونی. سطرها کلاس واقعی و ستون‌ها کلاس پیش‌بینی شده‌اند.



شکل ۶-۱۳: ماتریس درهم‌ریختگی مدل تصویر به همراه عروق روی آزمون کانونی. سطرها کلاس واقعی و ستون‌ها کلاس پیش‌بینی شده‌اند.



شکل ۶-۱۴: ماتریس درهم‌ریختگی مدل تصویر به‌همراه عروق و نشانگرها روی آزمون کانونی. سطرها کلاس واقعی و ستون‌ها کلاس پیش‌بینی شده‌اند.




شکل ۶-۱۵: نمودار اطمینان‌پذیری سه مدل روی آزمون کانونی (۱۳۳۱ تصویر) با پانزده سبد هم‌عرض. خط چین مورب کالیبراسیون کامل است.



جدول ۳-۶: عملکرد مدل‌های اصلی روی آزمون کانونی قفل‌شده ($N = 1331$)

مدل	ورودی و معماری	AUC	دقت متعادل	F1 ماکرو	Brier	ECE
نشانگرهای اسکالر	پنج نشانگر $\rightarrow$ XGBoost	۶۵۹۶.۰	۴۹۸۵.۰	۴۳۴۶.۰	۵۶۷۵.۰	۰.۵۰۲.۰
شبکه‌ی تصویری	تصویر $\rightarrow$ EfficientNet-B5 (۲۰۴۸) $\rightarrow$ طبقه‌بند خطی	۹۱۳۳.۰	۶۹۸۶.۰	۶۸۴۸.۰	۲۶۲۳.۰	۰.۴۹۷.۰
بازنمایی تصویری	تصویر $\rightarrow$ EfficientNet-B5 (۲۰۴۸) $\rightarrow$ XGBoost	۹۲۴۹.۰	۷۲۳۴.۰	۷۰۸۷.۰	۲۷۶۳.۰	۱.۰۲۸.۰
تصویر + نشانگرها	۲۰۴۸ تصویری + ۵ نشانگر XGBoost $\rightarrow$ (۲۰۵۳)	۹۲۶۰.۰	۷۲۰۴.۰	۷۰۹۳.۰	۲۶۹۰.۰	۰.۹۸۶.۰
شبکه‌ی نقشه‌ی عروق	نقشه‌ی عروق $\rightarrow$ EfficientNet-B4 (۱۷۹۲) $\rightarrow$ طبقه‌بند خطی	۸۳۷۲.۰	۶۲۰۰.۰	۵۸۸۷.۰	۳۸۱۲.۰	۰.۸۰۰.۰
تصویر + عروق	۲۰۴۸ تصویری + ۱۷۹۲ عروقی XGBoost $\rightarrow$ (۳۸۴۰)	۹۳۲۸.۰	۷۳۵۰.۰	۷۲۴۶.۰	۲۴۸۶.۰	۰.۹۲۱.۰
تصویر + عروق + نشانگرها	۲۰۴۸ تصویری + ۱۷۹۲ عروقی + ۵ نشانگر (۳۸۴۵) $\rightarrow$ XGBoost	۹۳۴۹.۰	۷۳۸۹.۰	۷۲۹۲.۰	۲۴۶۵.۰	۰.۹۲۱.۰

AUC، دقت متعادل و F1 ماکرو بزرگ‌تر بهتر و Brier و ECE کوچک‌تر بهتر هستند. عدد پررنگ بهترین مقدار هر ستون است. هیچ امتیاز ترکیبی ساخته نشده و مدل‌ها با نمره‌ی تجمیعی رتبه‌بندی نشده‌اند. مدل‌های ثانویه‌ی اکتشافی در این جدول نیامده‌اند.



شکل ۶-۱۶: تفاضل سطح زیر منحنی هر افزودنی نسبت به بازنمایی تصویری، با بازه‌ی اطمینان زوجی از بوت‌استرپ طبقه‌محور با ده هزار تکرار و بذر ثابت روی آزمون کانونی (۱۳۳۱ تصویر). خط چین صفر را نشان می‌دهد.

جدول ۶-۴: AUC هر کلاس به صورت یک‌دربرابریه روی آزمون کانونی ($N = 1331$)

مدل	Normal	Pre-Plus	Plus
نشانگرهای اسکالر	۶۵۳۲.۰	۷۶۶۴.۰	۵۵۹۲.۰
شبکه‌ی تصویری	۹۰۳۳.۰	۹۱۵۰.۰	۹۲۱۷.۰
بازنمایی تصویری	۹۱۶۸.۰	۹۳۱۳.۰	۹۲۶۷.۰
تصویر + نشانگرها	۹۱۸۷.۰	۹۳۵۴.۰	۹۲۳۹.۰
شبکه‌ی نقشه‌ی عروق	۸۲۲۸.۰	۸۲۹۹.۰	۸۵۸۹.۰
تصویر + عروق	۹۲۷۷.۰	۹۳۵۴.۰	۹۳۵۴.۰
تصویر + عروق + نشانگرها	۹۳۰۰.۰	۹۳۶۷.۰	۹۳۷۹.۰

Pre-Plus کوچک‌ترین کلاس آزمون (۱۴۰ مورد) و سخت‌ترین کلاس برای همه‌ی مدل‌ها است.



کلاس Pre-Plus کوچک‌ترین کلاس آزمون است و بیشترین جابه‌جایی را در ماتریس‌های درهم‌ریختگی دارد، ولی سطح زیر منحنی یک‌دربرابریه‌ی آن پایین‌ترین ستون جدول نیست؛ دشواری این کلاس در تصمیم آستانه‌ای و شمار کم نمونه‌هایش دیده می‌شود، نه لزوماً در توان رتبه‌بندی. برای نشانگرهای اسکالر وضع برعکس است.

۴-۱-۶ کالیبراسیون و جهت معیارهای آستانه‌ای

هیچ‌کدام از مدل‌های نمایش‌داده‌شده روی خط کالیبراسیون کامل نمی‌نشینند؛ در اطمینان پایین کم‌اطمینان و در اطمینان بالا پراطمینان‌اند. تابع زیان آموزش آنتروپی متقاطع وزن‌دار کلاس است؛ وزن‌های کلاس فراخوانی کلاس‌های کم‌فراوان را بالا می‌برند و دقت متعادل را بهتر می‌کنند، در حالی که احتمال‌های افراطی Brier و ECE را بدتر می‌کنند. این دو جهت مخالف هم‌زمان درست‌اند. مدل‌های نورونی ثانویه‌ی همین فصل همین الگو را نشان می‌دهند؛ مدل کنترل تثبیت‌شده (J0) دقت متعادل بالاتری از ترکیب تصویر و عروق دارد، ولی رتبه‌بندی و F1 ماکرو و کالیبراسیون آن بدتر است. دقت متعادل بالاتر در آن مدل نشانه‌ی مدل بهتر نیست.

۵-۱-۶ آمار زوجی مقایسه‌ی اصلی

تفاضل‌های زوجی ستون اصلی این فصل‌اند، نه رتبه‌ی خام جدول معیارها. همه‌ی آن‌ها با بوت‌استرپ زوجی طبقه‌بندی‌شده و بذر ثابت محاسبه شده‌اند و جدول زیر بازه‌ی اطمینان هر مقایسه را برای پنج معیار می‌آورد.

افزودن پنج نشانگر به بازنمایی تصویری تفاوت‌ناپذیری داد و بازه‌ی اطمینان آن صفر را در بر می‌گرفت. افزودن بازنمایی عروقی هم توان رتبه‌بندی و هم کیفیت احتمال را بهتر کرد و بازه‌ی هر دو معیار صفر را کنار می‌گذارد. افزودن نشانگرها پس از بازنمایی عروقی پشتیبانی‌نشده (جدول شکل مربوط). دامنه‌ی افزایش عروقی هم باید خوانده شود. تفاضل دقت متعادل و F1 ماکرو و ECE در همین مقایسه بازه‌ی شامل صفر دارند؛ پس افزایش پشتیبانی‌شده در توان رتبه‌بندی و کیفیت احتمال است و در معیارهای آستانه‌ای شاهد متناظری ندارد. دو مدل نشانگری C و G هم اکتشافی ثانویه‌اند.



جدول ۵-۶: آمار زوجی اصلی روی آزمون کانونی؛ بوتاسترپ زوجی طبقه‌بندی‌شده با ۱۰۰۰۰ تکرار و بذر ۴۲
($N = 1331$)

مقایسه	سنجه	تفاضل	کران پایین	کران بالا	p	خارج از صفر
C – بازنمایی تصویری (افزودن پنج نشانگر)	AUC	۰۰۱۰۸۵.۰+	-0.001691	+0.003868	۴۳۱۳.۰	خیر
C – بازنمایی تصویری	دقت متعادل	-0.003008	-0.019805	+0.012895	۷۱۷۱.۰	خیر
C – بازنمایی تصویری	F1 ماکرو	۰۰۰۶۹۱.۰+	-0.015127	+0.015549	۹۲۵۸.۰	خیر
C – بازنمایی تصویری	Brier	-0.007255	-0.015464	+0.000865	۰۸۱۹.۰	خیر
	ECE	-0.004253	-0.014093	+0.005995	۴۰۳۰.۰	خیر
E – بازنمایی تصویری (افزودن بازنمایی عروقی)	AUC	۰۰۷۹۳۸.۰+	+0.002630	+0.013131	۰۰۳۱.۰	بله
C – بازنمایی تصویری	دقت متعادل	۰۱۱۶۲۴.۰+	-0.011994	+0.034846	۳۲۷۸.۰	خیر
C – بازنمایی تصویری	F1 ماکرو	۰۱۵۹۱۵.۰+	-0.006211	+0.037655	۱۵۳۰.۰	خیر
C – بازنمایی تصویری	Brier	-0.027693	-0.043954	-0.011471	۰۰۱۱.۰	بله
	ECE	-0.010675	-0.026072	+0.003869	۱۶۴۲.۰	خیر
E – G (افزودن نشانگرها پس از عروق)	AUC	۰۰۲۰۳۹.۰+	-0.000274	+0.004397	۰۹۰۰.۰	خیر
C – بازنمایی تصویری	دقت متعادل	۰۰۳۸۴۶.۰+	-0.012053	+0.020061	۶۳۸۳.۰	خیر
C – بازنمایی تصویری	F1 ماکرو	۰۰۴۵۹۲.۰+	-0.010536	+0.019581	۵۴۴۰.۰	خیر
C – بازنمایی تصویری	Brier	-0.002075	-0.009236	+0.004947	۵۷۰۷.۰	خیر
	ECE	-0.000063	-0.009202	+0.011057	۹۹۰۶.۰	خیر

بازه‌ی اطمینان بر پایه‌ی صدک‌های ۵.۲ و ۵.۹۷ توزیع بوتاسترپ و مقدار p بر پایه‌ی توزیع مرکز‌محور دوطرفه است. تنها سنجه‌هایی که بازه‌ی آن‌ها صفر را شامل نمی‌شود، AUC و Brier در مقایسه‌ی E در برابر بازنمایی تصویری هستند؛ دقت متعادل، F1 ماکرو و ECE در همان مقایسه بازه‌ی شامل صفر دارند.



۶-۱-۶ ترکیب دیر هنگام: یک نتیجه‌ی منفی

مدل ترکیب دیر هنگام امتیاز دو مدل را با یک ضریب اختلاط وزنی مخلوط می‌کرد. این ضریب روی مرز شبکه اشباع شد؛ در نتیجه جدول احتمال آن با بازنمایی تصویری یکسان شد. این را شکست همان طرح ترکیب ثبت می‌کنیم، نه سود ترکیب. وقتی ضریب به مرز می‌رود، مدل به یکی از دو شاخه فرو می‌ریزد و شاهد مستقلی برای هم‌افزایی تولید نمی‌کند.

۶-۲ شواهد افزایشی پنج نشانگر اسکالر در همه‌ی رژیم‌های آزمون شده

پرسش این زیربخش باریک است. آیا پنج نشانگر اسکالر عروقی، فراتر از بازنمایی یادگرفته‌شده، اطلاعات پیش‌بینی‌کننده‌ی تازه‌ای اضافه می‌کنند؟ پاسخ به یک مقایسه‌ی تنها وابسته نیست، چون نتیجه می‌تواند به خانواده‌ی یادگیرنده، به شیوه‌ی ورود نشانگر و به منبع تصویربرداری بستگی داشته باشد. همین پرسش در هفت آزمون مستقل تکرار شد و معیار مشترک همه‌ی آن‌ها تفاضل سطح زیر منحنی با بازه‌ی اطمینان زوجی است. چهار آزمون روی آزمون تقسیم استاندارد قفل شده اجرا شده‌اند، دو مقایسه‌ی جدولی روی بازنمایی‌های تثبیت‌شده، یک مدل عصبی مشترک یادگیرنده و یک کنترل شرطی‌شده‌ی FiLM سه آزمون دیگر فولدهای منبع کنار گذاشته‌اند و در هر یک یک مرکز تصویربرداری کامل از برازش بیرون مانده است.

جدول زیر این هفت آزمون را کنار هم می‌گذارد. ستون‌ها تفاضل سطح زیر منحنی، دو کران بازه و مقدار احتمال را نشان می‌دهند و ستون آخر تفسیر کنترل‌شده‌ی هر سطر است. هیچ سطری یک امتیاز ترکیبی نیست و سطرها با هم جمع نمی‌شوند.

دو مقایسه‌ی جدولی روی آزمون قفل شده به یک نتیجه می‌رسند. افزودن پنج نشانگر به بازنمایی تصویری و افزودن همان پنج نشانگر پس از بازنمایی عروقی فضایی، هر دو بازه‌ی شامل صفر دارند و در چهار معیار دیگر هم بازه‌ی بیرون از صفر دیده نمی‌شود. هیچ‌یک از این دو مقایسه افزایش پشتیبانی‌شده نمی‌سازد.

در مدل عصبی مشترک جهت اثر عوض می‌شود. افزودن شاخه‌ی نشانگری به مدل H کاهش پشتیبانی‌شده‌ای در توان رتبه‌بندی می‌دهد و تنها بازه‌ی است که در این معیار صفر را کنار می‌گذارد. سه معیار دیگر همان مقایسه بی‌تفاوتی می‌مانند، پس آنچه افت کرده رتبه‌بندی است، نه کیفیت احتمال، و افت با حضور شاخه‌ی نشانگری همراه است.

کنترل FiLM تصویر متفاوتی می‌سازد. تفاضل رتبه‌بندی J1 و J0 بازه‌ی شامل صفر دارد، ولی کالیبراسیون در J1 بهتر است. این بهبود به نشانگرها نسبت داده نمی‌شود، چون تشخیص‌های همان




جدول ۶-۶: شواهد افزایشی پنج نشانگر اسکالر در همه‌ی رژیم‌های آزمون شده

آزمایش	تفاضل AUC	کران پایین	کران بالا	p	تفسیر
کانونی: C در برابر بازنمایی تصویری	۰۰۱۰۸۵.۰+	-0.001691	+0.003868	۴۳۱۳.۰	بدون افزایش پشتیبانی شده
کانونی: G در برابر E	۰۰۲۰۳۹.۰+	-0.000274	+0.004397	۰۹۰۰.۰	بدون افزایش پشتیبانی شده
شبکه‌ی مشترک یادگیرنده: I در برابر H	-0.009578	-0.016273	-0.002854	۰۰۴۹.۰	کاهش پشتیبانی شده
شرطی‌سازی FiLM: J1 در برابر J0	-0.002123	-0.004427	+0.000143	۰۶۸۲.۰	بدون افزایش پشتیبانی شده
منبع کنارگذاشته فارفوم: G در برابر E	-0.003581	-0.008233	+0.001189	۱۳۳۹.۰	بدون افزایش پشتیبانی شده
منبع کنارگذاشته فارابی: G در برابر E	۰۰۱۵۷۹.۰+	-0.002785	+0.005956	۴۸۳۹.۰	بدون افزایش پشتیبانی شده
منبع کنارگذاشته Plus (محدود): G در برابر E	-0.000446	-0.001982	+0.001100	۵۷۰۵.۰	بدون افزایش پشتیبانی شده
سطر آخر از AUC دودویی محدود «Normal در برابر Plus» استفاده می‌کند، زیرا منبع Plus هیچ مورد Pre-Plus ندارد؛ این سطر با سطرهای سه‌کلاسه قابل جمع‌بستن نیست. این جدول به‌معنای بی‌فایده بودن نشانگرها نیست؛ هیچ افزایش مثبت پشتیبانی‌شده‌ای مشاهده نشد و تنها بازه‌ای که صفر را کنار می‌گذارد منفی است.					




آزمایش خلاف آن را نشان می‌دهند؛ جانشین کردن هر نشانگر با میانگین آموزشی‌اش احتمال‌های منجمد را تغییر محسوسی نمی‌داد و شمار تغییر تصمیم در هر پنج نشانگر صفر ماند، یعنی شرطی‌ساز در عمل مانند نگاشت همانی رفتار کرده است. توضیح محتمل آن بهبود، تفاوت مقدار اولیه‌ی سر ترکیب میان J0 و J1 است، چون ساخت مازول‌های FiLM جریان تصادفی را جابه‌جا می‌کند. این یک محدودیت طرح تطبیقی است، نه اثر نشانگرها.

سه فولد منبع کنارگذاشته هم جهت مثبت پایداری نشان نمی‌دهند و در هیچ‌یک بازه از صفر جدا نمی‌شود. فولد منبع Plus هیچ مورد Pre-Plus ندارد، پس مقدار آن همان معیار محدود «Normal» در برابر «Plus» است و عددی سه‌کلاسه نیست.



شکل ۶-۱۷: شش آزمون مستقل سهم افزایشی پنج نشانگر اسکالر، با بازه‌ی اطمینان زوجی. سطر آخر ارزیابی محدود منبع Plus است.

جمع‌بندی این هفت آزمون یک جمله دارد. در هیچ رژیم‌ی افزایش مثبت نشانگرها پشتیبانی آماری نگرفت و تنها بازه‌ای که در معیار رتبه‌بندی صفر را کنار می‌گذارد منفی است. این الگو دو خوانش سازگار دارد و این آزمایش میان آن دو داوری نمی‌کند. خوانش نخست آن است که پنج ویژگی صریح، مستقل از بازنمایی یادگرفته‌شده، اطلاعات کمتری حمل می‌کنند؛ خوانش دوم آن است که کیفیت جداسازی برای آشکارکردن آن اطلاعات کافی نیست، چون نشانگرها روی ماسک عروق ساخته می‌شوند و خطای جداسازی به آن‌ها ارث می‌رسد. تفکیک این دو به آزمایشی نیاز دارد که خطای اندازه‌گیری را جداگانه کنترل کند و چنین آزمایشی انجام نشده است. بنابراین از این نتیجه هیچ ادعایی درباره‌ی بی‌فایده بودن نشانگرها ساخته نمی‌شود؛ هر پنج نشانگر توصیف‌گرهای عروقی تفسیرپذیر و آگاه‌به‌میدان دید باقی می‌مانند و



شکل ۳-۶: سهم افزایشی پنج نشانگر در ارزیابی با منبع کنار گذاشته، با بازه‌ی اطمینان زوجی. سطر Plus ارزیابی محدود است.

پشتیبانی نشدن سهم افزایشی‌شان در این مسئله‌ی سه‌کلاسه، معنای هندسی و قابلیت اندازه‌گیری آن‌ها را از میان نمی‌برد.

۳-۶ آزمایش‌های ثانویه و اکتشافی مدل‌های عصبی

سه آزمایش این زیربخش ثانویه و اکتشافی‌اند و روی همان آزمون تقسیم استاندارد قفل‌شده اجرا شده‌اند، پس بار تأییدی ندارند. انتخاب مدل در آن‌ها هم فقط با اعتبارسنجی انجام شد. جدول زیر معیارهای آزمون کانونی چهار مدل دو آزمایش نخست را کنار هم می‌گذارد.

۱-۳-۶ ترکیب مشترک یادگیرنده (Task 9)

در این آزمایش دو رمزگذار تثبیت‌شده‌ی تصویری و عروقی به بردارهای فشرده نگاشت شدند، یک شاخه‌ی تعامل روی آن دو ساخته شد و یک سر چندلایه تصمیم‌گرفت (مدل H)؛ مدل I همان ساختار را با یک شاخه‌ی نشانگری کوچک تکرار کرد. هیچ‌یک از این دو به ترکیب الحاقی تصویر و عروق نمی‌رسد. کاهش H نسبت به آن ترکیب پشتیبانی نمی‌شود و افزودن شاخه‌ی نشانگری به H کاهش پشتیبانی‌شده‌ای در رتبه‌بندی می‌دهد (جدول شکل مربوط).

معیارهای دیگر همان مقایسه‌ها یک‌سو نیستند. مدل H در برابر ترکیب الحاقی در دقت متعادل و F1 ماکرو و کیفیت احتمال عقب می‌ماند، در حالی که شاخه‌ی نشانگری در I هیچ‌یک از این معیارها را معنادار جابه‌جا نمی‌کند؛ یعنی آنچه در I افت کرد رتبه‌بندی بود، نه کالیبراسیون. منحنی‌های یادگیری نشان می‌دهند پس از آزادسازی وزن‌های رمزگذار، خطای آموزش یکنوا پایین رفت و خطای اعتبارسنجی بالا



جدول ۶-۷: آزمایش‌های ثانویه و اکتشافی معماری که از مدل‌های الحاقی تثبیت‌شده بهتر نشدند


مدل	AUC	دقت متعادل	F1 ماکرو	Brier	ECE	توضیح
ترکیب مشترک یادگیرنده (H)	۹۲۵۸.۰	۶۵۷۴.۰	۶۸۴۰.۰	۲۷۵۹.۰	۱۱۵۹.۰	دوره‌ی انتخاب‌شده ۴، مرحله‌ی دوم
ترکیب مشترک + نشانگر (I)	۹۱۶۲.۰	۶۷۳۰.۰	۶۹۷۸.۰	۲۷۸۶.۰	۱۱۵۲.۰	دوره‌ی انتخاب‌شده ۶، مرحله‌ی دوم
کنترل ترکیب تثبیت‌شده (J0)	۹۲۹۸.۰	۷۹۵۴.۰	۶۸۵۲.۰	۳۷۷۰.۰	۱۶۷۶.۰	دوره‌ی انتخاب‌شده ۱
شرطی FiLM (J1)	۹۲۷۶.۰	۷۸۹۷.۰	۶۸۸۵.۰	۳۶۱۴.۰	۱۵۳۶.۰	دوره‌ی انتخاب‌شده ۱

هیچ‌یک از این مدل‌ها نتیجه‌ی اصلی نیست. دقت متعادل بالاتر در J0 و J1 ناشی از پیش‌بینی تهاجمی کلاس‌های کم‌فراوان تحت تابع زیان وزن‌دار است و با AUC، F1 ماکرو و کالیبراسیون بدتر همراه است؛ بنابراین نباید به‌عنوان برتری خوانده شود.


رفت، و کمینه‌ی خطای اعتبارسنجی هر دو مدل پیش از آزادسازی بود. آنچه این آزمایش نشان می‌دهد بیش‌برازش سر مشترک روی نمونه‌های آموزش است، نه برتری معماری ترکیبی. این آزمایش ثانویه و اکتشافی است.

۲-۳-۶ شرطی‌سازی نشانگری با تعدیل کران‌دار (Task 10)


مدل J0 کنترل این آزمایش است؛ دو بازنمایی تثبیت‌شده به یک سر مشترک داده می‌شوند و هیچ نشانگری وارد مسیر نمی‌شود. مدل J1 همان ساختار را با تعدیل FiLM روی شاخه‌ی عروقی تکرار می‌کند؛ پارامترها باقی‌مانده و کران‌دار نوشته شدند تا مقدار اولیه نزدیک همانی بماند. تفاضل رتبه‌بندی J1 و J0 بازه‌ی شامل صفر دارد، ولی کیفیت احتمال در J1 بهتر است و دقت متعادل و F1 ماکرو بی‌تفاوت می‌مانند. این بهبود کالیبراسیون به نشانگرها نسبت داده نمی‌شود، چون تشخیص‌های همین آزمایش خلاف آن را نشان می‌دهند. تعدیل یادگرفته‌شده روی آزمون تقریباً همانی ماند و آزمون حساسیت تک‌نشانگری هم همین را تأیید می‌کند؛ جانشین کردن هر نشانگر با میانگین آموزشی‌اش احتمال‌های تثبیت‌شده‌ی J1 را تغییر محسوسی نمی‌داد و شمار تغییر تصمیم در هر پنج نشانگر صفر بود. توضیح محتمل آن بهبود یک محدودیت طرح تطبیقی است، نه یک یافته؛ ساخت مازول‌های شرطی جریان تصادفی را جابه‌جا می‌کند،




شکل ۶-۱۹: خطای آموزش و اعتبارسنجی مدل‌های تسک نه به‌ازای هر دوره؛ رمزگذارها پس از دوره‌ی سوم آزاد شده‌اند.




شکل ۶-۲۰: توان تمایز مدل‌های تسک نه روی اعتبارسنجی به‌ازای هر دوره.




شکل ۶-۲۱: خطای آموزش و اعتبارسنجی مدل‌های تسک ده به‌ازای هر دوره.




شکل ۶-۲۲: توان تمایز مدل‌های تسک ده روی اعتبارسنجی به‌ازای هر دوره.




شکل ۶-۲۳: تعدیل یادگرفته‌شده‌ی FiLM روی آزمون؛ خط‌چین‌ها حالت همانی را نشان می‌دهند.




شکل ۶-۲۴: تغییر مطلق احتمال پیش‌بینی مدل تثبیت‌شده هنگام جایگزینی هر نشانگر با میانگین آموزشی خود.




شکل ۶-۲۵: سطح زیر منحنی چندکلاسه‌ی مدل‌های تسک سیزده در برابر مدل‌های مرجع، روی آزمون کانونی (۱۳۳۱ تصویر).




شکل ۶-۲۶: دقت متعادل مدل‌های تسک سیزده در برابر مدل‌های مرجع، روی آزمون کانونی (۱۳۳۱ تصویر).




شکل ۶-۲۷: افیک ماکروی مدل‌های تسک سیزده در برابر مدل‌های مرجع، روی آزمون کانونی (۱۳۳۱ تصویر).




شکل ۶-۲۸: امتیاز Brier مدل‌های تسک سیزده در برابر مدل‌های مرجع، روی آزمون کانونی (۱۳۳۱ تصویر).




شکل ۶-۲۹: خطای کالیبراسیون انتظاری مدل‌های تسک سیزده در برابر مدل‌های مرجع، روی آزمون کانونی (۱۳۳۱ تصویر).



شکل ۶-۳۰: چهار مقایسه‌ی زوجی تسک سیزده، با بازه‌ی اطمینان از بوت‌استرپ طبقه‌محور با ده هزار تکرار و بدر ثابت روی آزمون کانونی (۱۳۳۱ تصویر).



شکل ۶-۳۱: خطای آموزش و اعتبارسنجی مدل تسک سیزده به ازای هر دوره؛ ستون‌های فقرات پس از دوره‌ی سوم آزاد شده‌اند.



شکل ۶-۳۲: توان تمایز مدل تسک سیزده روی اعتبارسنجی به ازای هر دوره.



پس مقدار اولیه‌ی سر ترکیب در J0 و J1 یکسان نیست و این دو مدل یک مقایسه‌ی کاملاً زوج شده نیستند. در منحنی‌های یادگیری هم هر دو مدل دوره‌ی نخست را انتخاب کردند و در پایان خطای آموزش پایین آمد در حالی که خطای اعتبارسنجی بالا رفت. این آزمایش هم ثانویه و اکتشافی است.

۳-۳-۶ استواری معماری نتیجه‌ی عروقی (Task 13)

این آزمایش یک ستون فقرات تصویری دیگر می‌آزماید؛ شبکه‌ی توجه نرم دوستون فقرات با ResNet50 و EfficientNet-B4 که یک بازنمایی توجهی می‌سازد (مدل L)، همان بازنمایی با طبقه‌بند جدولی (مدل M0) و همان بازنمایی به همراه نمایش عروقی (مدل M1). طبقه‌بند خطی سرتاسری L از طبقه‌بند جدولی روی همان بازنمایی ضعیف‌تر است و این دو هم خانواده نیستند، پس L مستقیماً با مدل‌های بازنمایی قابل مقایسه نیست.

مقایسه‌ی کلیدی M0 در برابر بازنمایی تصویری اصلی است که کاهش پشتیبانی شده‌ای در رتبه‌بندی و F1 ماکرو و کیفیت احتمال می‌دهد؛ یعنی بازنمایی توجهی آزموده شده در این پروتکل از بازنمایی تک‌ستون فقرات اصلی بدتر بود. این نتیجه یک آبلاسیون کنترل شده‌ی معماری نیست، چون دو خط لوله در یادگیرنده و رژیم آموزش هم تفاوت دارند. افزودن عروق در همین خانواده نتیجه‌ی جهت‌داری می‌دهد و بهبود پشتیبانی شده‌ای در رتبه‌بندی و F1 ماکرو و کیفیت احتمال می‌سازد، ولی همین M1 در برابر مدل‌های اصلی تفاوت معناداری با آن‌ها ندارد. پس مسیر عروقی در معماری دوم هم مکمل می‌ماند، بدون شاهد برتری خود آن معماری.

دوره‌ی برگزیده‌ی L پیش از بازکردن وزن‌های ستون فقرات قرار داشت و کمینه‌ی خطای اعتبارسنجی در دوره‌های بعد آمد؛ یعنی مرحله‌های تنظیم دقیق هرگز به سود نرسیدند و مدل برگزیده عملاً یک مدل مرحله‌ی نخست است. این آزمایش ثانویه و اکتشافی است.

۴-۳-۶ جمع‌بندی بیش‌برازش

در هر سه آزمایش نرونی این زیربخش، خطای آموزش کاهش یافت در حالی که عملکرد اعتبارسنجی افت کرد و کمینه‌ی خطای اعتبارسنجی پیش از بهترین دوره‌ی تنظیم دقیق یا در همان دوره‌ی نخست بود. سرهای عصبی این آزمایش‌ها روی نمونه‌های آموزش برای ظرفیت‌شان داده‌ی کافی ندارند و همین نتیجه‌ی منفی هر سه را توضیح می‌دهد. این سه آزمایش ثانویه و اکتشافی‌اند و هیچ‌کدام جای نتیجه‌ی مقایسه‌ی اصلی را نمی‌گیرد.



۴-۶ استواری معماری سهم عروقی و تشخیص توجه

دو پرسش این زیربخش جدا هستند. آیا سهم بازنمایی عروقی به یک استخراج کننده‌ی خاص ویژگی تصویری گره خورده است، و وزن‌های توجه این معماری‌ها تا چه اندازه قابل خواندن‌اند؟ هر دو پرسش روی آزمون تقسیم استاندارد قفل شده و با همان بوت‌استرپ زوجی طبقه‌بندی شده پاسخ داده می‌شوند. برای پرسش نخست، همان نمایش منجمد عروق به دو بازنمایی تصویری متفاوت اضافه شد و هر سطر کنترل هم‌تای فقط تصویری خودش را دارد. سطر نخست بازنمایی اصلی تک‌ستون فقرات EfficientNet-B5 است و سطر دوم بازنمایی دوستون فقرات توجهی که دو رمزگذار ResNet50 و EfficientNet-B4 را با توجه نرم ترکیب می‌کند. جدول زیر تفاضل‌ها را کنار هم می‌گذارد.


جدول ۶-۸: استواری سهم عروقی نسبت به معماری بازنمایی تصویری

بازنمایی تصویری	فقط تصویر	تصویر + عروق	تفاضل	کران پایین	کران بالا	p	تفاضل Brier
تک‌ستون فقرات اصلی (EfficientNet-B5)	۹۲۴۹.۰	۹۳۲۸.۰	۰۰۷۹۳۸.۰+	+0.002630	+0.013131	۰۰۳۱.۰	-0.027693
دوستون فقرات توجهی (+ ResNet50) (EfficientNet-B4)	۹۰۶۰.۰	۹۲۶۹.۰	۰۲۰۹۳۶.۰+	+0.011426	+0.030828	< 0.0001	-0.049181


هر سطر یک آزمایش مستقل با کنترل هم‌تای خودش است و دو سطر یک مقایسه‌ی مدل واحد نیستند. هر دو سطر از همان نمایش تثبیت شده‌ی ۱۷۹۲ بعدی عروق استفاده می‌کنند. اینکه سطر دوم افزایش بزرگ‌تری دارد به معنای برتری مدل دوستون فقرات نیست؛ AUC کنترل فقط تصویری آن در جدول پایین‌تر است.

افزودن عروق در هر دو سطر بازه‌ی بیرون از صفر و بهبود کیفیت احتمال می‌دهد. خواندن این الگو باید محدود بماند. بازتولید سهم عروقی با یک استخراج کننده‌ی دوم نشان می‌دهد این سهم به یک معماری تصویری خاص گره نخورده است، ولی به این معنا نیست که مدل دوستون فقرات برتر است. کنترل فقط تصویری همان مدل از بازنمایی اصلی ضعیف‌تر است و حتی پس از افزودن عروق هم این خط لوله از مدل‌های اصلی جدا نمی‌شود. پس دو سطر جدول را باید دو آزمایش مستقل با یادگیرنده و رژیم آموزش متفاوت خواند و افزایش عددی بزرگ‌تر در سطر دوم شاهی برای برتری آن معماری نیست (جدول شکل مربوط).


پرسش دوم به وزن‌های توجه همین معماری دوستون فقرات مربوط است. میانگین وزن ستون فقرات ResNet50 در اعتبارسنجی و آزمون به آستانه‌ی فروپاشی نزدیک نمی‌شود، ولی توزیع هر تصویر جداگانه




شکل ۳۳-۶: تفاضل سطح زیر منحنی از افزودن نمایش عروقی به دو بازنمایی تصویری متفاوت، با بازه‌ی اطمینان زوجی روی آزمون کانونی (۱۳۳۱ تصویر). این شکل برتری معماری دوستون فقرات را نشان نمی‌دهد.




شکل ۳۴-۶: میانگین وزن توجه به شاخه‌ی ResNet بر حسب کلاس واقعی در آزمون. این وزن‌ها فقط تشخیص توصیفی‌اند.



شکل ۶-۳۵: میانگین وزن توجه به شاخه‌ی ResNet بر حسب منبع تصویربرداری. وابستگی شدید به منبع، تفسیر بالینی این وزن‌ها را نامعتبر می‌کند.



شکل ۶-۳۶: توزیع وزن توجه شاخه‌ی ResNet روی اعتبارسنجی؛ دامنه‌ی صدک پنچ تا نود و پنچ با نشانگر میانه و میانگین.



شکل ۶-۳۷: توزیع وزن توجه شاخه‌ی ResNet روی آزمون؛ دامنه‌ی صدک پنج تا نود و پنج با نشانگر میانه و میانگین.

تقریباً دوقطبی است و وزن‌های میانی کم دیده می‌شوند. یعنی مدل برای هر تصویر تقریباً به یکی از دو ستون فقرات متعهد می‌شود.

این وزن‌ها هم به کلاس و هم به منبع وابسته‌اند و وابستگی به منبع از ترتیب کلاس‌ها پیروی نمی‌کند. چون توزیع وزن این‌گونه به منبع تصویربرداری گره خورده است، نمی‌توان آن را توضیح بیماری‌محور خواند و به‌عنوان شاهد تفسیری ارائه کرد. این وزن‌ها در انتخاب مدل هم هیچ نقشی نداشتند؛ انتخاب مدل و توقف زودهنگام فقط با اعتبارسنجی انجام شد و این تشخیص ثانویه و اکتشافی است.

۵-۶ جابه‌جایی دامنه‌ی بازنمایی‌ها و نشانگرها

پرسش این زیربخش توصیفی است. هر منبع کنارگذاشته در فضای بازنمایی‌های منجمد چه اندازه از منابع آموزشی جمع‌شده فاصله دارد، و این فاصله میان بلوک تصویری، بلوک عروقی و پنج نشانگر اسکالر چگونه پخش می‌شود؟ معیار، تفاوت میانگین استانداردشده‌ی هر ویژگی (SMD^{۷۴}) است، یعنی میانگین منبع کنارگذاشته منهای میانگین منابع آموزش، تقسیم بر انحراف معیار منابع آموزش. این آماره هیچ برچسب هدفی مصرف نمی‌کند، هیچ آزمون استنباطی در آن اجرا نشده و هیچ مدلی با آن بازتنظیم نشد.

جدول میانه و صدک‌های قدر مطلق SMD را برای دو بلوک نشان می‌دهد. بر پایه‌ی این میانه، بلوک عروقی در هر سه فولد جابه‌جاشده‌تر از بلوک تصویری است، در حالی که همین بلوک بیشترین سهم را

^{۷۴}تفاوت میانگین استانداردشده‌ی یک ویژگی میان دو جمعیت؛ معادل انگلیسی: Standardized Mean Difference



جدول ۶-۹: خلاصه‌ی جابه‌جایی دامنه‌ی نمایش‌های تثبیت‌شده؛ منبع کنارگذاشته در برابر منابع آموزشی
تجميع شده

منبع کنارگذاشته نمایش				میان‌ه‌ی قدر مطلق SMD	صدک ۹۰	صدک ۹۵	فاصله‌ی مرکزوار استانداردشده
Plus تصویری				۵۴۰۶.۰	۸۳۱۴.۱	۵۳۶۰.۲	۵۱۱.۵۶
Plus عروقی				۲۲۹۱.۱	۳۳۴۵.۲	۶۲۹۶.۲	۴۰۴.۶۳
فارفوم تصویری				۳۷۹۳.۰	۸۴۳۱.۰	۱۰۸۶.۱	۰۳۸.۲۶
فارفوم عروقی				۵۵۶۵.۰	۷۳۰۷.۰	۷۵۷۹.۰	۹۵۳.۲۲
فارابی تصویری				۴۹۶۶.۰	۱۲۵۸.۱	۴۸۴۷.۱	۲۵۳.۳۵
فارابی عروقی				۶۹۷۲.۰	۸۸۲۹.۰	۹۲۸۰.۰	۳۲۴.۲۸


SMD هر ویژگی برابر تفاضل میانگین منبع کنارگذاشته و میانگین منابع آموزشی تقسیم بر انحراف معیار منابع آموزشی است. هیچ برچسب هدفی در این آمارها استفاده نشده و هیچ مدلی با آن‌ها بازتنظیم نشد. نمایش عروقی در هر سه فولد جابه‌جاشده‌تر از نمایش تصویری است، ولی همان نمایش عروقی بیشترین سهم را در بهبود رتبه‌بندی دارد.

در بهبود رتبه‌بندی دارد؛ افزودن آن به بازنمایی تصویری در دو فولد سه‌کلاسه‌ی منبع کنارگذاشته تفاضل مثبت و معنادار داد. پس حساسیت به منبع به‌خودی‌خود آن چیزی نیست که یک بازنمایی را از سودمندی بازمی‌دارد.


دو آماره‌ی جدول یک روایت واحد نمی‌سازند. فاصله‌ی مرکزوار یک جمع سراسری روی همه‌ی ابعاد است و میان‌ه‌ی قدر مطلق SMD توزیع تک‌ویژگی را می‌سنجد، بنابراین این دو عدد لزوماً هم‌جهت نیستند و می‌توانند در یک فولد دو مسیر متفاوت بروند.

پنج نشانگر اسکالر هم از این جابه‌جایی بی‌بهره نیستند و اندازه‌ی جابه‌جایی آن‌ها تا حدود یک انحراف معیار کامل داده‌ی آموزش می‌رسد. علامت‌ها میان منابع برمی‌گردند؛ مثبت در Plus و منفی در دو منبع دیگر. یعنی یک نشانگر با تعریف ثابت در سه مرکز نه عدد یکسان و نه جهت یکسان به دست نمی‌دهد (شکل شکل مربوط).


این اعداد نشان می‌دهند بازنمایی‌ها و نشانگرها هر دو به منبع تصویربرداری حساس‌اند و بلوکی که بیشترین سهم را دارد، جابه‌جاشده‌ترین بلوک است. از این هم‌زمانی هیچ ادعای علی ساخته نمی‌شود و هیچ داوری درباره‌ی کیفیت یا بی‌کیفیتی یک بازنمایی از آن در نمی‌آید. آنچه با اطمینان گفته می‌شود دو چیز است. حساسیت به منبع به‌تنهایی یک بازنمایی را از سودمندی باز نمی‌دارد، و پنج نشانگر اسکالر



شکل ۶-۳۸: جابه‌جایی دامنه‌ی نمایش تصویری میان منبع کنارگذاشته و منابع آموزشی.



شکل ۶-۳۹: جابه‌جایی دامنه‌ی نمایش عروقی میان منبع کنارگذاشته و منابع آموزشی.




شکل ۶-۴: فاصله‌ی مرکزوار استاندارد شده میان منبع کنار گذاشته و منابع آموزشی در دو نمایش.

با این اندازه از جابه‌جایی برای انتقال بی‌تغییر به یک مرکز تازه مناسب نیستند و مقیاس ثابت آن‌ها میان مراکز جابه‌جا می‌شود.

۶-۶ ارزیابی با منبع کنار گذاشته

در این رژیم ارزیابی سه فولد ساخته شد و در هر فولد یک مرکز تصویربرداری کامل از فرآیند بیرون ماند. منبع کنار گذاشته در هیچ مرحله‌ای وارد نشد، نه در برازش، نه در اعتبارسنجی، نه در نرمال‌سازی، نه در هم‌ترازی، نه در توقف زودهنگام، نه در انتخاب آستانه‌ی تصمیم و نه حتی به‌صورت ویژگی بدون برجسب. هر فولد یک جمعیت، یک دامنه و یک مقیاس سنجش مستقل است و داده‌های آن با آزمون آمیخته و با فولدهای دیگر جمع نمی‌شود. این طراحی انتقال به مرکز تازه را می‌سنجد و اعتبارسنجی بالینی یا کارآزمایی آینده‌نگر نیست.

در دو فولد سه کلاسه، معیار رتبه‌بندی با افزودن نمایش عروقی به بازنمایی تصویری بهتر می‌شود و معیارهای دیگر هم در همین جهت حرکت می‌کنند. فولد منبع Plus هیچ مورد Pre-Plus ندارد، پس سطح زیر منحنی سه کلاسه برای آن تعریف نشده است و به‌جای آن معیار محدود دودویی «Normal» در برابر Plus گزارش می‌شود (جدول شکل مربوط).



شکل ۶-۴۱: تفاوت میانگین استانداردشده‌ی هر نشانگر میان منبع کنارگذاشته و منابع آموزشی.



جدول ۶-۱۰: عملکرد در ارزیابی با منبع کنار گذاشته؛ هیچ اطلاعاتی از منبع هدف در برازش یا پیش‌پردازش استفاده نشده است

منبع کنار گذاشته	مدل	سه کلاسه	محدود دودویی	دقت متعادل	F1 ماکرو	Brier	ECE
فارفوم	B	۷۸۷۵.۰		۶۳۲۸.۰	۶۳۳۹.۰	۵۴۷۵.۰	۲۱۴۳.۰
فارفوم	E	۸۰۹۸.۰		۶۶۳۵.۰	۶۵۹۰.۰	۵۱۰۷.۰	۱۸۳۲.۰
فارفوم	G	۸۰۶۲.۰		۶۵۷۶.۰	۶۵۱۴.۰	۵۲۰۴.۰	۱۹۹۱.۰
فارابی	B	۷۶۹۹.۰		۵۵۹۸.۰	۵۳۲۱.۰	۶۴۸۴.۰	۲۵۸۳.۰
فارابی	E	۷۸۲۹.۰		۵۸۶۰.۰	۵۷۲۰.۰	۶۱۸۷.۰	۲۳۹۱.۰
فارابی	G	۷۸۴۵.۰		۵۷۴۶.۰	۵۶۳۱.۰	۶۱۳۷.۰	۲۴۷۲.۰
Plus (محدود)	B	تعریف نشده	۹۸۳۸.۰	۸۸۸۷.۰	۸۶۷۹.۰	۱۳۰۸.۰	۰۳۲۴.۰
Plus (محدود)	E	تعریف نشده	۹۸۴۶.۰	۹۰۲۰.۰	۸۸۸۷.۰	۱۰۴۵.۰	۰۱۶۶.۰
Plus (محدود)	G	تعریف نشده	۹۸۴۱.۰	۹۰۲۹.۰	۸۸۸۶.۰	۰۹۶۹.۰	۰۱۷۱.۰


منبع Plus هیچ مورد Pre-Plus ندارد؛ بنابراین سه کلاسه برای آن تعریف نشده است و جایگزین نمی‌شود. ستون محدود دودویی یک سنجه‌ی جداگانه‌ی «Normal در برابر Plus» است و نباید با ستون سه کلاسه در یک محور یا یک میانگین تجمیع شود. تفاضل‌های زوجی در متن گزارش آمده‌اند.



قاعده‌ی ارزیابی محدود را باید دوباره خواند، چون این عدد به‌سادگی بدخوانده می‌شود. مقدار فولد Plus یک معیار دودویی جداگانه با برچسب صریح است که روی جمعیتی محاسبه شده که اکثریت آن Normal است. این عدد نباید با عددهای سه‌کلاسه در یک محور، یک جدول جمع‌شده یا یک میانگین تجمیع شود و نباید به‌عنوان شاهی برای انتقال بهتر خوانده شود.


افزودن پنج نشانگر اسکالر در هیچ فولدی تفاوت معنادار نمی‌سازد و تفاضل رتبه‌بندی G و E در هر سه فولد بازه‌ی شامل صفر دارد. تنها تفاضل سطح زیر منحنی در فولد محدود Plus هم از صفر جدا نمی‌شود.

فاصله با نتیجه‌ی آزمون آمیخته توصیفی است و آزمون زوجی ندارد، چون جمعیت‌ها یکی نیستند و تفاوت آن‌ها فقط مدل نیست. همان صورت‌بندی E که روی آزمون تقسیم استاندارد قفل‌شده بالاترین معیار را گرفته بود، در هر دو فولد سه‌کلاسه افت محسوسی نشان می‌دهد.




شکل ۶-۴۲: سطح زیر منحنی سه‌کلاسه در ارزیابی با منبع کنارگذاشته. هیچ اطلاعاتی از منبع هدف در برازش استفاده نشده است.

یک نکته‌ی روش‌شناختی هم باید ثبت شود. انتخاب مدل و توقف زودهنگام در هر فولد فقط با اعتبارسنجی داده‌های آموزشی انجام شد و هیچ تصمیمی با نگاه به منبع کنارگذاشته گرفته نشد. فاصله‌ی میان برازش روی دامنه‌های موجود و رفتار روی مرکز تازه بزرگ است و بهترین مدل روی اعتبارسنجی، بهترین مدل روی منبع تازه نیست. گزارش این فاصله محدودیت انتقال را اندازه‌پذیر می‌کند، ولی آن را برطرف نمی‌کند.



شکل ۶-۴۳: ارزیابی محدود منبع Plus به صورت دودویی Normal در برابر Plus. محور از ۹۷۵.۰ آغاز شده و برچسب گذاری شده است؛ این عدد جانشین سطح زیر منحنی سه کلاسه نیست.



شکل ۶-۴۴: سهم افزایشی نمایش عروقی در هر فولد منبع کنارگذاشته، با بازهی اطمینان زوجی. سطر Plus ارزیابی محدود است.



۷-۶ آزمون ناوردایی دامنه‌ی شرطی به کلاس

پرسش این آزمون این است که آیا هم‌تراز کردن صریح دو دامنه‌ی آموزشی، عملکرد بیماری را روی منبع کنارگذاشته بهتر می‌کند. برای هر فولد دو مدل هم‌تا ساخته شد. مدل K0 کنترل است، یک سر عصبی کوچک روی همان نمایش تثبیت‌شده و بدون هیچ جمله‌ی مربوط به دامنه. مدل K1 همان ساختار را با دو افزوده دارد، یک متمایزکننده‌ی دامنه با لایه‌ی معکوس‌کننده‌ی گرادیان و یک جمله‌ی MMD شرطی به کلاس روی نمایش مشترک. ضریب هر دو جمله ثابت بود و هیچ‌گاه با داده‌ی منبع کنارگذاشته تنظیم نشد.

شرطی به کلاس یعنی هم‌ترازی فقط میان نمونه‌هایی محاسبه می‌شود که برچسب بیماری یکسانی دارند. کلاسی که در یکی از دو دامنه‌ی آموزشی حضور ندارد از محاسبه کنار گذاشته می‌شود. در فولد منبع Plus کلاس Pre-Plus در آن منبع وجود ندارد و همین کلاس از هم‌ترازی حذف می‌شود. نتیجه‌ی اصلی نبود بهبود در تشخیص بیماری است. تفاضل K1 و K0 در معیار رتبه‌بندی برای هر دو فولد قابل مقایسه بازه‌ی شامل صفر دارد و هم‌ترازی در هیچ‌یک رتبه‌بندی را بهتر نکرد (جدول شکل مربوط).

اثرهای معنادار K1 در فولد فارفوم همه در جهت نامطلوب‌اند؛ F1 ماکرو و Brier و ECE بدتر می‌شوند، در حالی که دقت متعادل بی‌تفاوت است. در فولد فارابی تنها کیفیت احتمال تفاضل معنادار و کوچکی می‌دهد و بقیه‌ی معیارها بی‌اثرند. در فولد محدود Plus هم یک بهبود کوچک در معیار دودویی با افت F1 ماکرو همراه است؛ این دو حرکت ناهمسو هستند و خوانش یک‌سو نمی‌سازند.

تشخیص‌های جابه‌جایی تصویر دیگری می‌سازند. هم‌ترازی فاصله‌ی مرکزوار استاندارد شده و میانه‌ی قدر مطلق SMD را در هر سه فولد کاهش داد، با این حال قابلیت پیش‌بینی دامنه تقریباً بدون تغییر ماند. یک طبقه‌بند دامنه در اعتبارسنجی متقاطع روی همان داده، دامنه‌ی هر نمونه را با دقتی به مراتب بالاتر از سطح شانس تشخیص داد.


این دو تشخیص با هم اختلاف دارند و همین اختلاف نکته‌ی اصلی است. کم‌شدن فاصله‌ی مرکزوار و میانه‌ی قدر مطلق SMD نشان نمی‌دهد که هویت منبع از نمایش حذف شده است. هم‌ترازی فاصله‌ی حاشیه‌ای را کم کرد و شناسایی‌پذیری منبع را از میان نبرد. پس نتیجه‌ی این آزمون ناوردایی دامنه نیست؛ کاهش بخشی از جابه‌جایی توصیفی همراه با بدتر شدن کالبراسیون و F1 ماکرو در یک فولد، و بی‌اثری در رتبه‌بندی هر دو فولد قابل مقایسه است. چون ضریب‌ها ثابت بودند و روی منبع هدف تنظیمی انجام نشد، دامنه‌ی این نتیجه به همین پیکربندی محدود می‌ماند. این آزمون ثانویه و اکتشافی است.




جدول ۶-۱۱: نتایج آزمون ناوردایی دامنه‌ی شرطی به کلاس؛ K1 در برابر کنترل هم‌تای K0

منبع کنار گذاشته	سنجه	K0	K1	تفاضل	p
فارفوم	AUC سه کلاسه	۸۳۲۹.۰	۸۳۰۱.۰	-0.002796	۱۴۲۸.۰
فارفوم	دقت متعادل	۶۲۵۴.۰	۶۲۸۲.۰	۰.۰۲۷۲۷.۰+	۵۸۶۵.۰
فارفوم	F1 ماکرو	۵۷۱۶.۰	۵۵۹۳.۰	-0.012262	۰.۳۱۷.۰
فارفوم	Brier	۶۴۵۹.۰	۷۰۰۲.۰	۰.۵۴۲۵۳.۰+	< 0.0001
فارفوم	ECE	۲۶۰۵.۰	۲۹۹۶.۰	۰.۳۹۰۷۹.۰+	< 0.0001
فارابی	AUC سه کلاسه	۷۹۱۹.۰	۷۹۱۰.۰	-0.000883	۲۵۸۸.۰
فارابی	دقت متعادل	۵۳۷۳.۰	۵۳۴۶.۰	-0.002692	۵۰۸۹.۰
فارابی	F1 ماکرو	۵۰۱۱.۰	۵۰۳۵.۰	۰.۰۲۳۵۶.۰+	۶۳۵۱.۰
فارابی	Brier	۵۹۹۳.۰	۵۹۴۵.۰	-0.004839	۰.۰۰۹.۰
فارابی	ECE	۲۱۷۶.۰	۲۱۷۱.۰	-0.000528	۸۹۰۸.۰
Plus (محدود)	AUC دودویی			۰.۰۰۴۸۵.۰+	۰.۱۲۳.۰
Plus (محدود)	F1 ماکرو	۸۷۴۲.۰	۸۷۰۹.۰	-0.003273	۰.۱۳۷.۰
Plus (محدود)	Brier دودویی	۱۰۸۰.۰	۱۱۳۱.۰	۰.۰۵۱۲۱.۰+	< 0.0001


برای منبع Plus، AUC سه کلاسه تعریف نشده است و سطر AUC محدود دودویی یک سنجه‌ی جداگانه‌ی «Normal» در برابر Plus است. ضریب هر دو جمله‌ی ناوردایی روی ۱۰۰ ثابت بود و با داده‌ی منبع هدف تنظیم نشد. K1 در هیچ یک از دو فولد قابل مقایسه بهبود AUC نداد و اثرهای معنادار آن در فولد فارفوم نامطلوب بودند.




شکل ۶-۴۵: سطح زیر منحنی سه کلاسه‌ی دو مدل تسک دوازده روی منبع کنارگذاشته. منبع هدف در هیچ مرحله‌ای استفاده نشده است.




شکل ۶-۴۶: ارزیابی محدود منبع Plus در تسک دوازده به صورت دودویی Normal در برابر Plus. محور از ۹۸۵.۰ آغاز شده و برچسب گذاری شده است.



شکل ۶-۴۷: فاصله‌ی مرکزوار استاندارد شده میان دو دامنه‌ی آموزشی، پیش و پس از هم‌ترازی.



شکل ۶-۴۸: میانه‌ی قدر مطلق تفاوت میانگین استاندارد شده میان دو دامنه‌ی آموزشی، پیش و پس از هم‌ترازی.



شکل ۶-۴۹: دقت پیش‌بینی هویت دامنه از روی نمایش، پیش و پس از هم‌ترازی. خط‌چین سطح شانس را نشان می‌دهد.

۸-۶ جمع‌بندی تعمیم‌پذیری میان منابع

سه رژیم این فصل یک تصویر مشترک می‌سازند و این زیربخش آن تصویر را جمع می‌کند. هیچ تحلیل و جدول تازه‌ای این‌جا افزوده نمی‌شود.

مشاهده‌ی نخست این است که عملکرد مطلق روی منبع دیده‌نشده به‌مراتب پایین‌تر از آزمون آمیخته است. صورت‌بندی‌هایی که در آزمون آمیخته بالاترین معیارها را داشتند، در فولدهای منبع‌کنارگذاشته افت محسوس نشان می‌دهند. این اختلاف توصیفی است و آزمون زوجی ندارد، چون جمعیت‌ها متفاوت‌اند. مشاهده‌ی دوم افت کالیبراسیون است و این یکی از افت رتبه‌بندی جدا است. روی آزمون آمیخته احتمال‌های خروجی تا اندازه‌ای کالیبره بودند، ولی روی مرکز تازه ECE و Brier به‌شدت بالا می‌روند. برای هر کاربرد آستانه‌ای همین بخش از افت تعیین‌کننده است.

مشاهده‌ی سوم و قابل‌اتکاترین بخش این مجموعه، بازتولید سهم بازنمایی عروقی زیر جابه‌جایی منبع است. تفاضل E و B در هر دو فولد سه‌کلاسه بازه‌ی بیرون از صفر دارد و معیارهای دیگر در همان جهت حرکت می‌کنند؛ همین سهم با یک معماری تصویری متفاوت هم بازتولید شده بود. دامنه‌ی این ادعا همان دو فولد و همان صورت‌بندی‌هاست.



مشاهده‌ی چهارم نبود همین بازتولید برای پنج نشانگر اسکالر است. تفاضل G و E در هیچ‌یک از سه فولد از صفر جدا نمی‌شود و در رژیم‌های دیگر هم افزایش مثبت پشتیبانی‌شده‌ای برای این پنج عدد دیده نشد. بازنمایی عروقی فضایی زیر جابه‌جایی منبع سود خود را نگه می‌دارد و نشانگرهای اسکالر در این مسئله‌ی سه‌کلاسه چنین سودی نشان نمی‌دهند. این نامتقارنی به معنای بی‌فایده بودن نشانگرها نیست؛ معنای هندسی آن‌ها و قابلیت اندازه‌گیری‌شان سر جای خود می‌ماند.

این تصویر دو محدودیت دارد. نخست اینکه فقط یک روش هم‌ترازی با یک پیکربندی ثابت ضریب و بدون تنظیم روی منبع هدف آزموده شد، پس نتیجه‌ی منفی آن رژیم درباره‌ی همین پیاده‌سازی است. دوم اینکه گروه در منبع Plus و FARFUM-RoP بر پایه‌ی بیمار و در فارابی بر پایه‌ی معاینه تعریف شد، چون شناسه‌ی بیمار در فارابی موجود نبود؛ بنابراین نبود هم‌پوشانی در سطح شناسه‌ی گروه قابل دسترس تأیید شده است، ولی اثبات نبود هم‌پوشانی بیمار نیست. هیچ‌یک از فولدهای این فصل ارزیابی در سطح بیمار نیست.

در جمع، این فصل انتقال به مرکز تصویربرداری تازه را به عنوان یک محدودیت باقی‌مانده ثبت می‌کند و آن را قابلیت اثبات‌شده نمی‌خواند. آنچه زیر جابه‌جایی دوام آورد سهم بازنمایی عروقی بود و آنچه دوام نیاورد سطح مطلق عملکرد، کالیبراسیون و سهم افزایشی نشانگرها بود.

۹-۶ تفسیر تصمیم آزمون ناوردایی

نتیجه‌ی آزمون ناوردایی دامنه، خروجی دوم از حالت‌هایی است که پیش از اجرا تعریف شده بود. جابه‌جایی منبع اندازه‌پذیر وجود دارد و هم‌ترازی شرطی به کلاس عملکرد بیماری را روی منبع دیده‌نشده بهتر نکرد؛ در یک فولد هم کالیبراسیون و $F1$ ماکرو بدتر شدند. پس این آزمون یک نتیجه‌ی منفی با یک آسیب جانبی موضعی است، نه موفقیت و نه شکست کامل.

از این نتیجه یک فرضیه پیشنهاد می‌شود و همان‌جا برچسب می‌خورد که فرضیه است، نه یافته. شاید تفاوت مهم این مجموعه داده در نسبت میان برچسب و ویژگی از یک منبع به منبع دیگر باشد، نه در توزیع درون‌کلاسی که MMD شرطی به کلاس هدف می‌گیرد؛ اگر معنای عملیاتی یک برچسب روی دو مرکز یکسان نباشد، هم‌تراز کردن توزیع درون‌کلاس آن اختلاف را نمی‌بندد. این فرضیه آزموده نشده و فقط یک جهت برای کار بعدی است.

یافته‌ی مثبت این آزمون تنها کاهش بخشی از فاصله‌های توصیفی بود و با بهبود عملکرد بیماری همراه نشد؛ قابلیت پیش‌بینی دامنه پس از هم‌ترازی به شدت بالاتر از سطح شانس ماند، پس هویت منبع از نمایش حذف نشده است. نتیجه به همین پیکربندی محدود است.



فصل ۷

جمع‌بندی و نتیجه‌گیری

۱-۷ بحث، محدودیت‌ها و نتیجه‌گیری

این فصل نتایج آزمون تقسیم استاندارد قفل‌شده را تفسیر می‌کند، محدودیت‌های شناخته‌شده‌ی طرح را می‌آورد و مرزهای ادعای این گزارش را مشخص می‌سازد. هر تفسیر به همان رژیم‌ی نسبت داده می‌شود که آن نتیجه را تولید کرده است.

۱-۱-۷ پاسخ به سؤال‌های پژوهش

پرسش نخست این بود که آیا پنج نشانگر اسکالر عروقی به‌تنهایی پلاس را جدا می‌کنند. پاسخ این است که جدا می‌کنند، ولی ضعیف. مدل XGBoost روی همین پنج نشانگر به سطح زیر منحنی ۰.۶۵۹۶ رسید؛ این مقدار آشکارا از سطح شانس بالاتر و آشکارا از هر مدل تصویری این گزارش پایین‌تر است. تفکیک کلاس‌ها هم نامتوازن است و کلاسی که مسئله‌ی اصلی است، ضعیف‌ترین تفکیک را دارد.

پرسش دوم این بود که آیا افزودن همین نشانگرها به یک بازنمایی تصویری یادگرفته‌شده سود افزایشی می‌سازد. روی تقسیم استاندارد قفل‌شده، پاسخ در هیچ‌یک از رژیم‌های آزمون‌شده مثبت و پشتیبانی‌شده نبود. در مقایسه‌ی اصلی روی بازنمایی تصویری، تفاضل ناچیز بود و بازه‌ی اطمینان صفر را در بر می‌گرفت؛ همین الگو در معیارهای دیگر و در افزودن نشانگرها پس از بازنمایی عروقی تکرار شد. در شبکه‌ی ترکیب مشترک یادگیرنده، شاخه‌ی نشانگری کاهش پشتیبانی‌شده داد و در طرح شرطی FiLM اثر قابل‌سنجشی نداشت. حذف هر نشانگر به‌تنهایی هیچ تصمیمی را جابه‌جا نکرد، پس بهبود کالیبراسیون در مقایسه‌ی مدل شرطی با کنترل هم‌تایش به نشانگرها نسبت داده نمی‌شود.

در برابر این تصویر، بازنمایی فضایی عروق سود پشتیبانی‌شده داد؛ افزودن آن به بازنمایی تصویری توان رتبه‌بندی و کیفیت احتمال را بهتر کرد. این افزایش در ارزیابی منبع‌کنارگذاشته، که هیچ داده‌ای از منبع هدف، حتی ویژگی بدون برچسب، در آن به کار نرفت، و با یک معماری تصویری متفاوت نیز تکرار شد. روی منبع Plus، که ارزیابی آن به مقایسه‌ی محدود Normal در برابر Plus محدود می‌ماند، این



سیگنال دیده نشد.

جمع‌بندی دو پرسش آن است که نشانگرهای اسکالر در رژیم‌های آزمون‌شده سود افزایشی پشتیبانی‌شده‌ای فراتر از بازنمایی یادگرفته‌شده نداشتند و در یک رژیم کاهش پشتیبانی‌شده داشتند، در حالی که نقشه‌ی عروق اطلاعاتی دارد که با پنج خلاصه‌ی اسکالر از دست می‌رود. این نتیجه را نمی‌توان به بی‌اطلاعاتی نشانگرها یا به برتری تضمین‌شده‌ی عروق در هر معماری تصویری تعمیم داد.

۲-۱-۷ محدودیت‌ها

جدول ۷-۱: محدودیت‌های کلیدی و اثر آن‌ها بر دامنه‌ی ادعا

محدودیت	اثر بر ادعا
گروه‌بندی فارابی در سطح معاینه	استقلال در سطح بیمار برای این منبع اثبات نشده است
نبود ماسک مرجع متخصص برای این جمعیت	سهم ویژگی و سهم کیفیت اندازه‌گیری از هم جدا نمی‌شود
نبود Pre-Plus در منبع Plus	ارزیابی آن منبع فقط دودویی محدود است
استفاده‌ی پیشین از آزمون قفل‌شده	تسک‌های بعدی تحلیل مجدد اکتشافی‌اند، نه آزمون تأییدی
نابرابری اندازه‌ی آموزش فولدها	جابه‌جایی دامنه با اندازه‌ی مجموعه‌ی آموزش مخلوط می‌شود

جدول بالا محدودیت‌های اصلی و اثر هر یک بر دامنه‌ی ادعا را کنار هم می‌گذارد. سه محدودیت دیگر هم باید ثبت شود. مدل‌های نورونی این پروژه بیش‌برازش کردند؛ خطای آموزش کاهش یافت در حالی که عملکرد اعتبارسنجی افت کرد و مجموعه‌ی آموزش برای ظرفیت این سرها کم است. از میان روش‌های هم‌ترازی دامنه تنها یک روش و آن هم در یک تنظیم ثابت ضریب آزمون شد، بدون هیچ تنظیمی روی منبع هدف. طرح تطبیقی FiLM نیز از نظر فنی کاملاً یکنواخت نیست، زیرا مقدار اولیه‌ی سر ترکیب در دو مدل جفت‌شده یکسان نیست؛ پس تفسیر علی به‌بود کالبراسیون در آن مقایسه مجاز نیست. وزن‌های توجه مدل دوستونی به‌شدت وابسته به منبع تصویربرداری‌اند و فقط توصیفی می‌مانند.

۳-۱-۷ ارزش علمی

دست‌آورد نخست این پروژه یک خط لوله‌ی اندازه‌گیری بازتولیدپذیر است. پنج نشانگر نهایی عروقی با تعریف مخرج پوشش بر پایه‌ی مساحت محتوا و با در نظر گرفتن میدان دید تثبیت شدند و نسخه‌ی پذیرفته‌شده اثر انگشت خود را دارد. تقسیم کانونی با اثر انگشت جمعیت قفل شد و جدول نشانگرها روی همان جمعیت بازسازی شد.



آزمون قفل شده یک بار به کار رفت و انتخاب مدل و آستانه فقط بر پایه‌ی اعتبارسنجی انجام شد. همه‌ی مقایسه‌ها با یک پروتکل واحد سنجیده شده‌اند، بوت‌استرپ زوجی طبقه‌محور با بذر ثابت، و ارزیابی منبع‌کنار گذاشته هیچ اطلاعاتی از منبع هدف به کار نبرد، حتی ویژگی بدون برچسب. پیاده‌سازی ناوردایی دامنه با لایه‌ی معکوس‌کننده‌ی گرادیان و فاصله‌ی بیشینه‌ی میانگین‌ها شرطی به کلاس، با ضریب ثابت و بدون تنظیم روی هدف اجرا شد. طرح FiLM نیز به صورت تعدیل باقی‌مانده‌ی کران‌دار با مقدار اولیه‌ی نزدیک به همانی نوشته شد تا بازنمایی عروقی تخریب نشود.

در سمت نتیجه، این گزارش رژیم‌هایی را مستند می‌کند که در آن‌ها نشانگرهای اسکالر سود افزایشی پشتیبانی‌شده ساختند و یک رژیم را که در آن کاهش پشتیبانی‌شده داشتند. ثبت این نتیجه‌ی منفی با پروتکل اعلام‌شده بخشی از دستاورد روش‌شناختی کار است.

۴-۱-۷ پیامد برای کاربرد پژوهشی

این نتایج توان رتبه‌بندی مدل را روی برچسب ثبت‌شده در همین داده نشان می‌دهد و به‌تنهایی برای ادعای کاربرد بالینی کافی نیست. هیچ‌یک از اعداد این گزارش حاصل اعتبارسنجی خارجی نیست، هیچ‌کدام جایگزین ارزیابی متخصص نمی‌شود و هیچ‌یک آمادگی برای استفاده در محیط واقعی را نشان نمی‌دهد. فاصله‌ی عملکرد میان منابع نشان می‌دهد نتیجه‌ی یک مرکز بی‌واسطه به مرکز دیگر منتقل نمی‌شود، و هیچ مطالعه‌ی کاربردپذیری با متخصصان چشم‌پزشکی در این پروژه انجام نشد؛ پس درباره‌ی بهبود گردش کار یا کاهش زمان تصمیم‌دهی مطرح نمی‌شود.

۵-۱-۷ کار آینده

هر پیشنهاد این بخش از یک محدودیت مشخص در همین گزارش بیرون می‌آید. نخست، تهیه‌ی ماسک عروق با بازبینی متخصص روی همین جمعیت لازم است، تا سهم ناکافی بودن خود ویژگی و سهم خطای اندازه‌گیری از هم جدا شود. دوم، دسترسی به شناسه‌ی بیمار در فارابی باید فراهم شود تا ارزیابی کنارگذاشتن یک بیمار در هر مرحله با گروه‌بندی واقعی در سطح بیمار اجرا شود. سوم، طرح شرطی‌سازی باید با کران بازتر یا بدون کران و با مقدار اولیه‌ی ثابت‌شده برای سر ترکیب تکرار شود، تا روشن شود نتیجه‌ی منفی FiLM به خود نشانگرها مربوط است یا به محافظه‌کاری طرح. چهارم، از میان روش‌های هم‌ترازی دامنه تنها یک روش و در یک تنظیم ثابت آزمون شد؛ آزمودن روش‌های دیگر با معیار انتخاب اعلام‌شده‌ی پیش از اجرا تصویر کامل‌تری می‌دهد.



پنجم، اگر قرار باشد ادعایی درباره‌ی گردش کار بالینی مطرح شود، پیش از آن یک مطالعه‌ی خواننده با طرح مشخص لازم است. تا آن زمان دامنه‌ی این گزارش به رتبه‌بندی روی برچسب ثبت‌شده محدود می‌ماند.



پیوست‌ها

۲-۷ ضمایم

این پیوست آزمایش‌های معماری که نتیجه‌ی مثبت ندادند، تشخیص‌های شرطی‌سازی و توجه، منحنی‌های یادگیری و داده‌ی خام شکل‌ها را نگه می‌دارد.


۱-۲-۷ آزمایش‌های منفی معماری

مدل‌های نورونی ثانویه‌ی اکتشافی روی همان آزمون کانونی ارزیابی شدند تا سنجیده شود آیا ترکیب مشترک و یادگیرنده یا شرطی‌سازی با نشانگر می‌تواند از ترکیب ساده‌ی بازنمایی‌های منجمد پیشی بگیرد. پاسخ روی این جمعیت منفی بود. چون این آزمایش‌ها پس از مقایسه‌ی اصلی و روی همان تقسیم اجرا شدند، تحلیل مجدد اکتشافی محسوب می‌شوند و بار تأییدی ندارند. جدول کامل معیارهای این مدل‌ها در فصل نتایج آمده است.

در خواندن نتایج باید معیارها را جدا دید. مدل‌های J0 و J1 دقت متعادل بالاتری از ترکیب بازنمایی‌های منجمد دارند، ولی سطح زیر منحنی، F1 ماکرو و کالیبراسیون آنان بدتر است؛ تابع زیان وزن‌دار کلاس اقلیت را تهاجمی پیش‌بینی می‌کند و دقت متعادل بالاتر در این مورد به معنای برتری مدل نیست. در هر سه مدل نورونی این پیوست، خطای آموزش کاهش یافت در حالی که عملکرد اعتبارسنجی افت کرد.

۲-۲-۷ تشخیص‌های FiLM

پارامترهای تعدیل در آزمون به همانی نزدیک ماندند. آزمون حساسیت تک‌نشانگری هم نشان داد جایگزینی هر نشانگر با میانگین آموزشی‌اش تصمیم هیچ نمونه‌ای را جابه‌جا نمی‌کند، پس بهبود کالیبراسیون در مقایسه‌ی مدل شرطی با کنترل هم‌تایش به نشانگرها نسبت داده نمی‌شود و به تفاوت مقدار اولیه‌ی سر ترکیب میان دو مدل جفت‌شده مربوط می‌ماند.



شکل ۷-۱: میانگین وزن توجه هر شاخه در هر دوره؛ خطوط چین آستانه‌های فروپاشی را نشان می‌دهند.

۳-۲-۷ منحنی‌های یادگیری Task 9

در این تسک وزن‌های رمزگذار در میانه‌ی آموزش باز شدند. خطای آموزش کاهش یافت در حالی که خطای اعتبارسنجی بالا رفت و کمینه‌ی خطای اعتبارسنجی هر دو مدل در دوره‌ی نخست ثبت شد؛ بهترین سطح زیر منحنی اعتبارسنجی مدل H هم از مدل B در حالت تثبیت‌شده پایین‌تر ماند.

۴-۲-۷ منحنی‌های یادگیری و توجه Task 13

در تسک سیزدهم دوره‌ی انتخاب‌شده پیش از کمینه‌ی خطای اعتبارسنجی قرار گرفت و خطای آموزش کاهش یافت در حالی که عملکرد اعتبارسنجی افت کرد. وزن ستون شبکه‌ی باقی‌مانده در آزمون به آستانه‌ی هشدار نزدیک نیست، پس فروپاشی توجه رخ نداده است؛ ولی توزیع آن برای هر تصویر تقریباً دوقطبی و به‌شدت وابسته به منبع تصویربرداری است. بنابراین این مقادیر فقط توصیفی‌اند و برای تفسیر بالینی توجه به کار نمی‌روند.

۵-۲-۷ اثر انگشت مصنوعات و یکپارچگی

برای هر مصنوع این پروژه، از فایل تقسیم تا وزن مدل‌ها و خروجی پیش‌بینی‌ها، چکیده‌ی SHA-256 محاسبه و ثبت شده است. پیش از استناد به هر نتیجه بررسی می‌شود که مصنوع مورد استناد همان فایل‌ای باشد که در فهرست ثبت شده است و مصنوعات تسک‌های پیشین تغییر نکرده باشند.



۶-۲-۷ داده‌ی خام شکل‌ها

هر مقدار عددی که در شکل‌های این گزارش رسم شده است، یک فایل داده‌ی ماشین‌خوان همراه دارد. این فایل‌ها با قالب csv^{۷۵} در پوشه‌ی tables/report/source_data/ نگه داشته می‌شوند و نام هر فایل با شناسه‌ی شکل متناظر آن هم‌خوان است. فایل هر شکل همان مقادیر ورودی رسم را در خود دارد، پس خواننده می‌تواند هر عدد شکل را مستقیماً با متن گزارش و با جدول‌های فصل نتایج مقابله کند.

۷-۲-۷ قواعد نام‌گذاری و تعریف گروه

در منبع Plus، نشانه‌های نام فایل مثل سن حاملگی، وزن تولد و شماره سری به شناسه گروه تبدیل می‌شوند. در فارابی، شناسه یکتای معاینه همان گروه است و پسوند نام فایل، تصویر داخل همان معاینه را مشخص می‌کند. تعریف گروه در دو منبع یکسان نیست و همین تفاوت در تفسیر ادعای استقلال نمونه‌ها اثر می‌گذارد؛ در فارابی هم‌پوشانی در سطح معاینه بررسی شده است، نه در سطح بیمار.

۸-۲-۷ اثر انگشت تقسیم

اثر انگشت تقسیم رسمی مورد استناد این گزارش برابر است با

0d4c3b3a60761ca1bda88924dbc0cbf6f1be604a6e10dd5e981e40b73f05f9c8

هر نتیجه‌ی رسمی با همین اثر انگشت، اثر انگشت پیکربندی و بذر همراه است تا به همان نسخه‌ی داده پیوند داده شود. این مقدار، چکیده‌ی SHA-256^{۷۶} فایل تقسیم جمعیت کانونی است.

^{۷۵}قالب متنی جدولی با مقادیر جدا شده با کاما؛ معادل انگلیسی: comma-separated values
^{۷۶}تابع درهم‌ساز رمزنگاری‌شده؛ معادل انگلیسی: Secure Hash Algorithm 256



مراجع

- [۱] Chiang, M. F., et al. (۲۰۲۱). International Classification of Retinopathy of Prematurity, Third Edition. *Ophthalmology*, ۱۲۸(۱۰), e51–e68. <https://doi.org/10.1016/j.ophttha.2021.05.031>.
- [۲] Fiererson, W. M., et al. (۲۰۱۸). Screening Examination of Premature Infants for Retinopathy of Prematurity. *Pediatrics*, ۱۴۲(۴), e20183061. <https://doi.org/10.1542/peds.2018-3061>.
- [۳] Fhima, J., et al. (۲۰۲۲). PVBM: A Python Vasculature Biomarker Toolbox Based on Retinal Blood Vessel Segmentation. <https://arxiv.org/abs/2208.00392>.
مستندات ابزار در <https://github.com/aim-lab/PVBM> قرار دارد.
- [۴] Tan, M., and Le, Q. V. (۲۰۱۹). EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks. *Proceedings of ICML*, ۹۷, ۶۱۰۵–۶۱۱۴. <https://proceedings.mlr.press/v97/tan19a.html>.
- [۵] Mahdian, N. *Vascular Biomarker-Guided ROP Classification*. <https://github.com/nikimahdian/vascular-biomarker-guided-rop-classification>.
پرونده‌های /artifacts و data/splits/all.csv مبنای اعداد گزارش شده‌اند.
- [۶] Wittenberg, L. A., Jonsson, N. J., Chan, R. V. P., and Chiang, M. F. (۲۰۱۱). Computer-Based Image Analysis for Plus Disease Diagnosis in Retinopathy of Prematurity. *Journal of Pediatric Ophthalmology and Strabismus*, ۴۹(۱), ۱۱–۲۰. <https://pmc.ncbi.nlm.nih.gov/articles/PMC4036800/>.
- [۷] Yildiz, V. M., Tian, P., Yildiz, I., et al. (۲۰۲۰). Plus Disease in Retinopathy of Prematurity: Convolutional Neural Network Performance Using a Combined Neural



Network and Feature Extraction Approach. *Translational Vision Science & Technology*, ۹(۲), ۱۰. <https://doi.org/10.1167/tvst.9.2.10>.

- [۸] Agrawal, R., Walambe, R., Kotecha, K., Gaikwad, A., Deshpande, C. M., and Kulkarni, S. (۲۰۲۳). HVDROPDB datasets for research in retinopathy of prematurity. *Data in Brief*, ۵۲, ۱۰۹۸۳۹. <https://doi.org/10.1016/j.dib.2023.109839>. Dataset: <https://data.mendeley.com/datasets/xw5xc7xrmp/2>.

این مجموعه ۱۰۰ تصویر با ماسک دستی عروق و ۱۰۰ تصویر با ماسک دستی دیسک بینایی دارد و اعداد مرجع دایس در فصل نتایج از جدول‌های ۲ و ۳ همین مقاله گرفته شده است.



چکیده انگلیسی

Plus Disease Detection in Retinopathy of Prematurity

Vascular Biomarkers and Frozen Image Representations for Plus Disease Detection

Abstract

Retinopathy of prematurity is a leading cause of preventable childhood blindness, and treatment decisions depend on recognising Plus disease. That recognition rests on expert visual assessment of fundus images and remains observer-dependent near its boundaries. This project asks whether five scalar vascular biomarkers separate Plus on their own, and whether adding them to a learned image representation provides an incremental contribution.

Three components were built. The measurement component computes five vascular biomarkers with field-of-view-aware definitions and a content-area coverage denominator. The representation component provides two frozen encoders, an RGB representation from EfficientNet-B5 and a vessel-map representation from EfficientNet-B4. Eight primary models were built from these components, alongside secondary neural models. The cohort contains 8,862 fundus images from 414 groups across three acquisition sources, split by group so that no group appears in more than one partition.

Adding the spatial vessel representation to the image representation produced a supported improvement in ranking performance and in probability quality, and the increment replicated under source-held-out evaluation, which uses no target-source information of any kind, and also with a different RGB architecture. The five scalar biomarkers produced no supported incremental contribution in any tested regime; used alone they ranked well



above chance yet below every image-based model.

Cross-source performance is markedly lower than pooled-test performance, no expert reference mask exists for this cohort and the Plus source supports only the restricted Normal-versus-Plus comparison, so these results demonstrate ranking ability against the recorded label and are not evidence of clinical readiness, not a replacement for expert assessment, and not externally validated.

Keywords: retinopathy of prematurity, Plus disease, vascular biomarkers, frozen image representations, vessel representation fusion, grouped split with fingerprint, paired bootstrap, source-held-out evaluation